KDT 해커톤 2기 제출 자료 | 도메인 참조 데이터 감사 보고서

MBC 지상파 주간 편성표(8월 5주) 메타데이터 구조 및 파싱 감사

KDT 해커톤 2기 참조 문서 정밀 검토 · EPG 스케줄 ETL·OCR/PDF 테이블 추출 피드백

작성 팀 / 작성자	검토 대상 문서	검토 일시	검토 기관 / 담당
우티달 / IPTV 채널 추천 참조자료 (2기)	1개 (PDF 1p, 8/26~9/1 주간 편성표)	2024년 08월 22일	DMDG 기술심사위원회 (Sherlock & Craig)

GOOD (B+)

82

TOTAL SCORE / 100

1. EPG 원천 시계열 정보 밀도
90
2. 접근성 메타(자막·수어·해설·UHD)
92
3. PDF 표 파싱/정규화 난이도 대응
72
4. 시간대·장르 태깅 파이프라인 연계
80
5. 다채널 확장성(지상파→IPTV)
76

1. 총평 및 핵심 심사 의견 (Executive Summary)

핵심 EPG 원천 B+

🏆 **프로그램명·방영분·연령등급뿐 아니라 UHD·자막·한국수어·화면해설·재방송 여부까지 완비한 고밀도 EPG 마스터**

지상파 1주일(8/26 월~9/1 일) 새벽 5시~심야 시간대 편성이 시간(시)·분(00~55)·등급(ALL/7/12/15/19)·로컬/릴레이 및 배리어프리(자막·수어·화면해설) 아이콘과 함께 담긴 실전 원천 문서입니다. IPTV/방송 추천 해커톤에서 '현재 방영 중 프로그램 매칭'의 Ground Truth 역할을 합니다.

⚠️ **비정형 PDF 시각 격자(시간-요일 2D 그리드 + 아이콘 마커)로 인해 단순 텍스트 추출 시 시간·요일 매칭 붕괴**

`pymupdf` 단순 `get_text()`로 읽으면 시각적 셀 경계가 무시되어 방송 시간과 프로그램명이 어긋나며, '수어/화면해설/자막' 배지는 텍스트가 아닌 이미지/도형 좌표로 매핑되어 있습니다. 추천 API 연동을 위해서는 반드시 PyMuPDF `find_tables()`/`words` 좌표 클러스터링 기반 JSON/CSV EPG 정규화 파이프라인이 필요합니다.

검토 대상 파일명	파일 형식	검증 상태	핵심 검증 결과 요약
MBC_8월_5주(1).pdf	PDF (EPG 편성표 1p)	파싱 보완	풍부한 실시간 편성 메타 포함, 2D 표 좌표 정규화 파서 구축 필수

2. 비정형 PDF EPG 스케줄 표 파싱 및 실시간 추천 DB 적재 감사

정밀 감사

📌 [PDF 데이터 엔지니어링 진단] X-Y 좌표 기반 주간 편성표 스키마 정규화

ETL 파서 필수

원천 시각 요소	단순 텍스트 추출 문제	정규화 권장 스키마	추천·접근성 활용
상단 요일 헤더(8/26~9/1)	줄글로 풀리며 칼럼 소실	X좌표 구간별 7개 요일 컬럼 버킷 할당	실시간 요일·시간 조회 쿼리
좌측 시(Hour) + 셀 내 분(00~55)	시·분 분리되어 엉킴	Y좌표 행 그룹핑 + 정규표현식 `^(\d{2})\s`	`start_ts`, `end_ts`, `duration_min`
장르·재방·특집 표기	`(재)`, `금토드라마`, `스페셜` 미분류	정규식 타이틀 클리너 + TMDB/Naver 메타 조인	협업필터링/장르 매칭 정확도 향상
UHD/자막/수어/화면해설 마크	아이콘 누락	셀 내 Color/Symbol 좌표 매칭 Boolean 플래그	시각·청각 장애인 맞춤 접근성 채널 필터

📌 [해커톤 연계 가치] 편성표 × 배리어프리(수어·화면해설) 추천 확장

접근성 시너지

- **장애인 접근성 추천 특화:** 동일 KDT 해커톤의 시각장애인/이동취약계층 과제와 연계해 '화면해설 제공 실시간 프로그램 우선 추천' 필드로 쓰면 ESG/공공 해커톤 심사에서 독보적 가산점을 받습니다.

> 💡 **기술심사위원회 종합 소견**
>
> 기획·데이터 파이프라인·모델 평가·실시간 서빙 간 정합성을 확보하고 3장의 교정 솔루션을 즉시 적용하면 실무 수준의 완성도와 데모 설득력을 크게 높일 수 있습니다.

3. 개선 솔루션 및 기술 보완 가이드 (Actionable Fixes)

교정 솔루션

📌 영역별 핵심 보완 항목

Action Items

해당 절 / 영역	발견된 문제점 및 보완점	수정 제안 (Action Item)
2D 표 파싱	일주일 편성표 PDF가 1페이지 고밀도 표라 일반 `get_text()` 순서 뒤섞임	PyMuPDF `page.get_text('words')` (x0, y0, text) 좌표 기반 7요일 컬럼 슬라이싱 파서 구현
지속 갱신	단발성 8월 5주 PDF 수동 수집 시 서비스 지속 불가	MBC/지상파/IPTV EPG 공개 XML·웹 편성표 일일 배치 크롤러 + S3 저장 자동화
장르 부재	편성표만으로는 시청자 추천에 필요한 세부 장르·출연진·줄거리 부족	추출 프로그램명 기준 네이버/KOBIS/OTT 메타 API 자동 조인 보강

🔧 [Fix 1] PyMuPDF 좌표 기반 7개 요일 컬럼 버킷 편성표 정규화 스케치
words = page.get_text('words') # (x0, y0, x1, y1, text, block, line, word_no) day_bins = [120, 210, 300, 390, 480, 570, 660, 750] # 요일 X경계 좌표 for x0, y0, _, _, txt, *_ in words: col_idx = bisect.bisect_right(day_bins, x0) - 1 # 월(0)~일(6) 매핑 후 y0 순 정렬
🔧 [Fix 2] 정규화된 실시간 EPG JSON 레코드 표준 스키마
epg_row = {'channel':'MBC', 'air_date':'2024-08-28', 'start_min':'19:40', 'title':'일일드라마 용감무쌍 용수정', 'is_rerun':False, 'has_caption':True, 'has_sign_lang':True}

4. 실전 고도화 전략 & 최종 검증 체크리스트 (Success Strategy)

검증 가이드

📺 1. '지금 틀면 바로 보는 실시간 EPG JSON DB' 구축 해커톤 MVP

1페이지 PDF를 깔끔한 250개+ JSON 레코드로 변환한 ETL 노트북만 추가해도 기술 점수가 크게 오릅니다.

♿ 2. 화면해설/수어/자막 배리어프리 필터 차별화 ESG 가산점

편성표 우측 상단에 이미 명시된 화면해설·수어 정보를 실제 추천 API 필터 키로 살려내세요.

🔁 3. 재방송`(재)`·스페셜 자동 디듀플리케이션 데이터 품질

'나 혼자 산다(본방)'와 '(재)/(스페셜)'을 같은 프로그램 ID로 묶어야 추천 다양성이 무너지지 않습니다.

⚡ 4. KDT 다른 팀(우티달) 추천 엔진의 즉시 입력 데이터로 제공 팀 연계

정제된 `mbc_epg_normalized.csv`를 우티달 채널 추천 알고리즘의 입력 스키마로 바로 연결하세요.

📋 최종 완결성 점검 체크리스트 (Sherlock Final Checklist)

구분	점검 항목	점검 내용 및 기준	상태
파서	**X-Y 좌표 기반 7요일 EPG 파서 구현**	월~일 프로그램·시작분·등급 추출 정합성 98%+	구현 필요
메타	**장르/줄거리 외부 API 조인 보강**	프로그램명 클리닝 후 장르 대/소분류 태깅	보완 권고
확장	**화면해설·수어·자막 Boolean 컬럼화**	배리어프리 맞춤 채널 필터 지원	권장 추가

DMDG (당목담글) 교육사업본부 & AI 연구소 기술인증위원회

본 기술 검토서는 제출된 기획서·발표자료·산출물의 데이터 정합성, 모델링 타당성, 아키텍처 완성도 및 발표 설득력을 종합 평가하여 발행되었습니다.
우티달 / IPTV 채널 추천 참조자료 (2기) 의 지속적인 성장과 성공적인 프로젝트 완수를 응원합니다.