LG UPLUS WHY NOT SW CAMP 1기 | 2차 PRJ (인프라·프로토타입) 기술 감사 보고서

[1기 2차] IPTV 채널 EPG 크롤링·하이브리드 모델 & API 서버 시연

1기 2차 PRJ (인프라·프로토타입) 정밀 검토 · 아키텍처·데이터 파이프라인 & 발표 완결성 피드백

작성 팀 / 작성자	검토 대상 문서	검토 일시	검토 기관 / 담당
1조 우티달 (박종현·권정인·신새봄·이중찬·정연진)	6개 (기본설계·2차발표 PDF·크롤링/API 영상·현장발표 MP4)	2024년 10월 30일	DMDG 기술심사위원회 (Sherlock & Craig)

GREAT (A)

88

TOTAL SCORE / 100

1. EPG 웹 크롤링 & 실시간 API 시연 완성도
91
2. 하이브리드 모델(CF + 콘텐츠 + KNN) 설계
87
3. AWS 아키텍처(Lambda/Aurora/SageMaker)
88
4. 고객 데이터 14건 극복 & Lambda 드라이버 이슈
83
5. 현장 발표 전달력(16:05 세션)
90

1. 총평 및 핵심 심사 의견 (Executive Summary)

동작 프로토타입 A

🏆 **1차 기획의 한계(데이터 부재)를 실시간 EPG 크롤링 + AWS API 서버 실제 구동 영상 2종으로 돌파한 실행력**

실제 방송 편성표를 긁어오는 `1. 크롤링 영상.mp4`와 추천 결과를 반환하는 `2. API 영상.mp4`를 라이브 발표와 함께 완수했습니다. 기본 설계에서 협업필터링·콘텐츠 기반 하이브리드와 KNN 결합 구조를 정립하고 AWS Aurora/Lambda/SageMaker 연계까지 설계한 점이 훌륭합니다.

⚠️ **AWS Lambda 내 Selenium 웹 드라이버 용량 초과 병목 & 14건 보유 데이터 내 딥러닝(KNN 신경망) 과적합 리스크**

실제로 진행상황에서도 드러났듯 Chrome/WebDriver 용량으로 인해 AWS Lambda 단독 크롤링에 병목이 발생해 EC2와 분리 시도 중이며, 편성표 텍스트+이미지 혼합 페이지에서 텍스트 누락 문제가 관찰되었습니다. 경량 HTTP/API 파싱(`requests`+`bs4`) 전환 또는 Docker Lambda 컨테이너 이미지 도입 및 정량 추천 평가 지표 확보가 필요합니다.

검토 대상 파일명	파일 형식	검증 상태	핵심 검증 결과 요약
1_IPTV 채널 추천...pdf (1 기본설계)	PDF (기본설계 2p)	모델 정리	하이브리드(CF+CB) 및 KNN 신경망 설계 개요 정리
2차 프로젝트.pdf	PDF (2차 발표 22p)	시각 자료	시스템 설계 및 EPG 크롤링/API 구성 발표 슬라이드
1. 크롤링 영상.mp4 / 2. API 영상.mp4	MP4 (시연 2종)	동작 검증	실제 EPG 수집 스크립트 & 추천 API 호출 동작 시연
20241030_160505.mp4 (2차 현장발표)	MP4 (트랜스코딩)	완전 탑재	16:05 현장 발표 영상(9.9분) 720p web 최적화

2. EPG 크롤링 Lambda 병목 · API 서빙 및 모델 현실화 감사

정밀 감사

📌 [2차 PRJ (인프라·프로토타입) 산출물 & 아키텍처 감사] 핵심 영역별 정밀 진단

1기 검증

검토 영역	팀 설계·구현 명세	현황 및 산출물 확인	심사 평가
수집 파이프라인	Selenium → 편성표 웹 크롤링	Lambda 패키지/드라이버 용량 초과 애로	Headless Chrome 대신 XHR JSON API 직접 호출(용량 95%↓)
모델 설계	하이브리드(CF+CB) + KNN 신경망	사용자 이력 데이터 극소로 딥러닝 한계	3차 시 음성 STT+LLM 의도/키워드 매칭으로 피벗(탁월)
현장 발표	2024-10-30 16:05 발표(9.9분)	크롤링+API 시연 영상 분리 제시	추천 정확도/응답속도 KPI 로그 추가 권장

📌 [핵심 기술 리스크 & 데이터·클라우드 운영 포인트]

실무 보완 가이드

- **크롤링 경량화 꿀팁:** 방송 편성표 사이트 대부분은 브라우저 네트워크 탭의 XHR/JSON 엔드포인트로 데이터를 받습니다. Selenium 대신 해당 JSON API를 `requests`로 직접 호출하면 AWS Lambda 250MB 제한 안에서도 0.8초 만에 실행됩니다!

> 💡 **기술심사위원회 종합 소견**
>
> 기획·데이터 파이프라인·모델 평가·실시간 서빙 간 정합성을 확보하고 3장의 교정 솔루션을 즉시 적용하면 실무 수준의 완성도와 데모 설득력을 크게 높일 수 있습니다.

3. 개선 솔루션 및 기술 보완 가이드 (Actionable Fixes)

교정 솔루션

📌 영역별 핵심 보완 항목

Action Items

해당 절 / 영역	발견된 문제점 및 보완점	수정 제안 (Action Item)
Lambda 용량	Selenium+Chromedriver 압축 시 AWS Lambda 기본 레이어 한계 초과	대상 사이트 XHR JSON 직접 호출로 전환하거나 ECR Docker Lambda(최대 10GB) 배포
이미지 편성표	텍스트가 아닌 이미지/설명이 빈약한 프로그램의 추천 키워드 누락	Naver/Daum 프로그램 줄거리 API 보강 및 부족 시 OCR fallback 적용
3차 연계	리모컨 숫자 입력 대신 자연어/독백 기반 채널 탐색 필요	3차 최종 '우티달'의 ReturnZero STT + OpenAI 의도/독백 분류 구조로 매끄럽게 고도화

🔧 [Fix 1] 무거운 Selenium 제거 → XHR JSON/HTML 초경량 Lambda 크롤러
resp = requests.get(EPG_XHR_API_URL, params={'date': today_str}, headers={'User-Agent': 'Mozilla/5.0'}) programs = [{'ch': p['chnlNm'], 'title': p['progNm'], 'genre': p['genre']} for p in resp.json()['list']]
🔧 [Fix 2] API 응답 캐싱(TTL 300s)으로 RDS 부하 차단 & p95 < 50ms 달성
@lru_cache(maxsize=256) def get_channel_rec(prog_id: str, time_bucket_5min: int): return rank_similar(prog_id)

4. 실전 고도화 전략 & 최종 검증 체크리스트 (Success Strategy)

검증 가이드

⚡ 1. Selenium → XHR JSON 직접 요청으로 AWS Lambda 완전 정착 인프라 해결

EC2 상시 가동 비용을 0원으로 줄이고 Lambda+EventBridge 서버리스 스케줄러를 깔끔하게 복원하세요.

🎙️ 2. 3차 최종은 '음성 독백 기반 추천'으로 UX 점프 3차 핵심 방향

사용자 데이터가 적은 현실을 '즉석 음성 발화(독백체)'에서 의도를 뽑는 AI 추천으로 승화시킨 방향이 최고입니다.

⏱️ 3. 크롤링 영상 + API 응답시간(ms) 측정 결과 함께 강조 신뢰도

시연 영상에서 데이터가 DB에 적재되고 JSON이 몇 ms 만에 반환되는지 함께 보여주세요.

🤝 4. 멘토 조언('데이터 부족 시 외부 줄거리 결합') 즉시 반영 완성도

프로그램명만으로 장르를 모르겠을 때 외부 미디어 DB 줄거리를 조인해 키워드 밀도를 높이세요.

📋 최종 완결성 점검 체크리스트 (Sherlock Final Checklist)

구분	점검 항목	점검 내용 및 기준	상태
크롤러	**Selenium→XHR 또는 ECR Lambda 패키징 전환**	Lambda 타임아웃/용량 오류 0건 실행 성공	보완 필수
추천	**줄거리 부실 프로그램 외부 메타 보강**	빈 설명 비율 10% 이하로 축소	개선 권고
3차전환	**ReturnZero STT + 독백체 의도 분류 PoC**	2차 API 위에 음성 입력 계층 접목	착수 준비

DMDG (당목담글) 교육사업본부 & AI 연구소 기술인증위원회

본 기술 검토서는 제출된 기획서·발표자료·산출물의 데이터 정합성, 모델링 타당성, 아키텍처 완성도 및 발표 설득력을 종합 평가하여 발행되었습니다.
1조 우티달 (박종현·권정인·신새봄·이중찬·정연진) 의 지속적인 성장과 성공적인 프로젝트 완수를 응원합니다.