[2차 프로젝트]

- 선택 모델

1) 초기응대

- STT api : 리턴제로 api (키워드 부스팅으로 오인식률 낮추기)

2) 키워드 추출 및 상담 연결

- NLP
  → KoNLPy: 불용어 제거 및 형태소 분석
  → TF-IDF: 문장 내 중요한 단어 추출
  → KoBERT: 문맥 이해를 기반으로 한 고급 키워드 추출
  → Elasticsearch: 기존 상담 데이터와의 빠른 비교 및 검색
  (autoML – SageMaker Autopilot, AutoKeras, Google Cloud AutoML 중 하나 쓰면 좋음)

3) 상담 진행

- TTS api : 네이버 CLOVA TTS api

4) 상담 후 처리 (추가 문의사항)

- STT api : 리턴제로 api

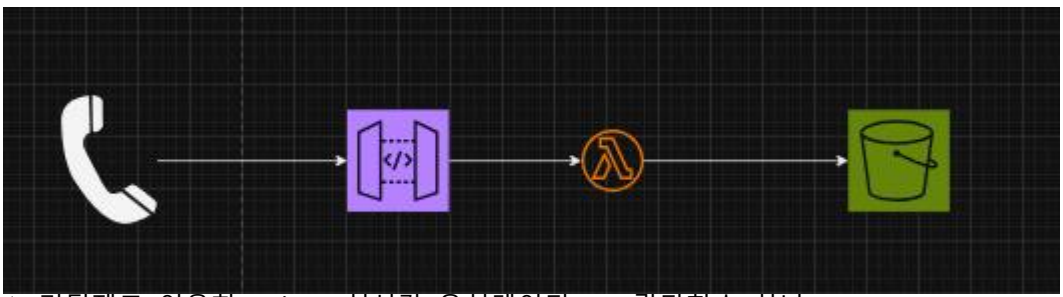
5) 데이터 저장 및 관리

- X

- 데이터 유형(수집, 적재, 용량)

1) 비정형 – 상담 음성 데이터 (mp3)
   - 지금 나와 있는 공공데이터로는 AI Hub에 상담 음성 데이터 100GB인데,
     저희는 LG u+ 상담 데이터를 받으면 좋을 것 같습니다.
2) 정형 – STT 상담 데이터, 상담 답변 데이터, 보완 데이터

- Pipe line



1. 리턴제로 이용한 api -> 실시간 음성데이터, stt 람다함수 하나
2. 텍스트 데이터 추출 -> 주요 언어 추출해서 테이블 형식으로 s3에 저장(athena사용해서 rds 역할 대신하게 한다음에 s3에 저장)
3. 네이버 클로바 api -> tts 이용해서 사용자에게 제공(자동 실행해서 답변 제공)

이 모든 코드들은 s3에 저장되어 있음