LG UPLUS WHY NOT SW CAMP 1기 | 2차 PRJ (인프라·프로토타입) 기술 감사 보고서

[1기 2차] 모바일 TV 로그 AWS Kinesis·Glue ETL & Surprise 추천 시연

1기 2차 PRJ (인프라·프로토타입) 정밀 검토 · 아키텍처·데이터 파이프라인 & 발표 완결성 피드백

작성 팀 / 작성자	검토 대상 문서	검토 일시	검토 기관 / 담당
5조 DATA로 (4조 발표) (김승훈·곽현철·조진형·양현우·서정임)	7개 (기본설계·발표 PDF·PPTX·시연 MP4·현장발표 MP4·ZIP)	2024년 10월 30일	DMDG 기술심사위원회 (Sherlock & Craig)

GREAT (A)

90

TOTAL SCORE / 100

1. AWS API→Kinesis→S3→Glue→Lambda→RDS E2E
95
2. Flask 로그 정형화(Content+ID 테이블 조인)
90
3. Python Surprise 협업필터링 프로토타입
87
4. 라이브 시연영상(`시연영상_241030.mp4` 33MB)
90
5. 현장 발표 전달력(16:16 피날레, 16.8분)
88

1. 총평 및 핵심 심사 의견 (Executive Summary)

클라우드 ETL 모범 A

🏆 **cURL/API POST → Kinesis Firehose → S3 → Glue Crawler(5분 주기 ETL) → Lambda 트리거 → RDS 자동 적재 E2E 완주**

데이터 엔지니어링 캠프의 본질에 가장 충실한 풀 자동화 파이프라인을 2차에서 실제로 구축·검증했습니다. 단순 이론이 아니라 실제 `GET /movie_details/1`·`/recommendations` HTTP 로그에서 ID/콘텐츠 테이블을 매칭 정형화하고, 5분 단위 Glue ETL과 Lambda RDS 적재, Surprise 추천 대시보드까지 동작 영상(`시연영상_241030.mp4`)으로 완벽히 증명했습니다.

⚠️ **`localhost(127.0.0.1)` 로그 형식 의존·Glue 5분 배치 비용 최적화 및 Surprise Cold-start(신규 유저/콘텐츠) 대응 보강 필요**

2차 설계의 Glue 5분 주기 트리거는 데모엔 좋으나 상시 운영 시 DPU 과금 부담이 크고, Python Surprise 협업필터링(SVD/KNNBasic)은 평점/시청로그가 없는 신규 사용자(Cold-start)에게 추천을 못 내주는 구조적 약점이 있습니다. 3차 최종(영화 스트리밍 웹사이트)에서는 콘텐츠 장르/감독 유사도 폴백과 웹앱 통합 DB 스키마 고도화가 필요합니다.

검토 대상 파일명	파일 형식	검증 상태	핵심 검증 결과 요약
5_TV이용행태...pdf (1 기본설계)	PDF (기본설계 1p)	스택 결정	AWS Personalize 기각(비용) → Python Surprise 채택 근거 합리적
DATA로_모바일TV...241030.pdf / PPTX	PDF+PPTX (22p)	엔지니어링 A	API→Firehose→Glue→Lambda→RDS 전체 단계 스크린샷/다이어그램 완비
시연영상_241030.mp4	MP4 (시연 33.3MB)	실동작 완비	실제 API 로그 생성 → AWS 파이프라인 적재 → 웹 추천 결과 시연
20241030_161630.mp4 (2차 현장발표)	MP4 (트랜스코딩)	완전 탑재	16:16 마지막 발표(16.8분, 원본 2.01GiB → 720p web 경량화)

2. AWS 서버리스 ETL · Glue 스케줄 비용 & Surprise 콜드스타트 감사

정밀 감사

📌 [2차 PRJ (인프라·프로토타입) 산출물 & 아키텍처 감사] 핵심 영역별 정밀 진단

1기 검증

검토 영역	팀 설계·구현 명세	현황 및 산출물 확인	심사 평가
스트리밍 수집	API GW → Kinesis Firehose → S3	트래픽 버퍼링 및 원본 S3 백업(Data Lake) 우수	파티션 `year/month/day/` 분할로 스캔 최적화
ETL 자동화	Glue Crawler + 5분 스케줄 + Lambda → RDS	완전 무인 정형화 및 트리거 정상 구동	발표 외 기간엔 Glue 1일/1시간 or On-demand 전환
추천 엔진	Python Surprise (AWS Personalize 대체)	비용 0원 & 커스텀 유연성 확보	신규유저용 장르/빈도 기반 폴백 하이브리드 필수

📌 [핵심 기술 리스크 & 데이터·클라우드 운영 포인트]

실무 보완 가이드

- **2.01 GiB 원본 영상 압축 성공 사례:** 본 팀의 2차 발표 원본 녹화(`20241030_161630.mp4`)는 2.011 GiB로 GitHub 단일 파일 상한(2 GiB)을 넘겼으나 720p H.264 `+faststart` 최적화로 빠르고 선명한 웹 스트리밍이 가능해졌습니다.

> 💡 **기술심사위원회 종합 소견**
>
> 기획·데이터 파이프라인·모델 평가·실시간 서빙 간 정합성을 확보하고 3장의 교정 솔루션을 즉시 적용하면 실무 수준의 완성도와 데모 설득력을 크게 높일 수 있습니다.

3. 개선 솔루션 및 기술 보완 가이드 (Actionable Fixes)

교정 솔루션

📌 영역별 핵심 보완 항목

Action Items

해당 절 / 영역	발견된 문제점 및 보완점	수정 제안 (Action Item)
비용 최적화	AWS Glue Job 5분(288회/일) 상시 스케줄 시 실습 크레딧 급속 소진 위험	Firehose 버퍼링(60s) 후 소규모 JSON 변환은 Glue 대신 경량 Lambda 직행 고려
콜드 스타트	Surprise 협업필터링은 최소 3~5편 시청이력 없는 신규 유저 추천 불가	온보딩 선호 장르 3개 선택 + 장르/배우 TF-IDF 유사도 1차 폴백 엔진 결합
모바일→영화 확장	2차 모바일 TV 로그 → 3차 영화 스트리밍 사이트 전환 시 메타데이터(포스터·감독·줄거리) 필수	Selenium 기반 영화정보/키워드/평점 사전 스크래핑(`영화정보스크래핑.csv`) 조기 구축

🔧 [Fix 1] 신규 유저 Cold-Start 방어형 Hybrid(Surprise CF + TF-IDF 장르) 라우터
if user_watch_count(uid) < 3: return content_based_genre_recs(user_selected_genres, movies_df, top_k=10) return surprise_svd.predict_top_k(uid, unseen_movies, k=10)
🔧 [Fix 2] S3 Data Lake 파티션 경로 & Glue 크롤링 스캔 비용 90% 절감
s3_key = f'raw-logs/year={dt:%Y}/month={dt:%m}/day={dt:%d}/{uuid4()}.json'

4. 실전 고도화 전략 & 최종 검증 체크리스트 (Success Strategy)

검증 가이드

⚙️ 1. 'AWS Personalize 비용 기각 → 오픈소스 Surprise+Glue 직접 구축' 스토리 아키텍트 역량

무조건 비싼 관리형 AI를 쓰지 않고 비용 대비 효과(TCO)를 계산해 아키텍처를 짠 논리가 심사위원 최고 호평 포인트입니다.

🎞️ 2. 3차 최종은 실제 보고 클릭할 수 있는 'OTT 영화 스트리밍 UI'로 완성 체감 퀄리티

정형화된 로그가 다시 웹 추천 캐러셀을 실시간으로 바꾸는 폐루프(Closed-loop)를 3차 최종 웹에 구현하세요.

⏱️ 3. Glue 크롤러/잡 스케줄 크레딧 관리 철저 운영 안정

크레딧 고갈로 발표 전날 AWS 계정이 막히지 않도록 평시엔 스케줄러를 끄고 시연·테스트 시에만 켜세요.

💉 4. 추천 성능 오프라인 RMSE/Precision@5 측정 표 추가 모델 검증

Surprise SVD/KNNBasic/BaselineOnly 3종 모델의 K-Fold RMSE 비교 수치를 3차 발표에 꼭 넣으세요.

📋 최종 완결성 점검 체크리스트 (Sherlock Final Checklist)

구분	점검 항목	점검 내용 및 기준	상태
하이브리드	**Surprise CF + 신규유저 콘텐츠 유사도 폴백**	Cold-start 유저 추천 빈 화면 0건 달성	3차 필수
비용	**Glue 5분 상시 잡 종료 → 시연/이벤트 트리거 전환**	AWS 실습 크레딧 잔액 보호 확인	즉시 점검
스크래핑	**영화 제목·포스터·장르·감독·키워드 DB 구축**	3차 OTT 웹 UI 렌더링용 메타데이터 완비	진행 예정

DMDG (당목담글) 교육사업본부 & AI 연구소 기술인증위원회

본 기술 검토서는 제출된 기획서·발표자료·산출물의 데이터 정합성, 모델링 타당성, 아키텍처 완성도 및 발표 설득력을 종합 평가하여 발행되었습니다.
5조 DATA로 (4조 발표) (김승훈·곽현철·조진형·양현우·서정임) 의 지속적인 성장과 성공적인 프로젝트 완수를 응원합니다.