대한경영정보학회
「경영과 정보연구」 제40권 제4호 2021년 12월
http://dx.doi.org/10.29214/damis.2021.40.4.002

사전학습 언어 모델을 활용한 트랜스포머 기반 텍스트 요약†

송의석* · 김남규**

〈요 약〉

소셜 미디어의 등장으로 많은 양의 텍스트 데이터가 온라인상에서 생산 및 유통되면서, 정보 이용자가 방대한 정보로부터 필요한 정보만을 추려내는 작업은 더욱 어려워지게 되었다. 이로 인해 많은 양의 텍스트를 자동으로 요약하기 위한 다양한 시도가 이루어지고 있으며, 특히 최근에는 풍부한 표현의 요약문을 새롭게 생성할 수 있는 추상 요약 접근법에 대한 연구가 활발히 수행되고 있다. 추상 요약 분야에서는 신경망 기반의 트랜스포머 모델이 우수한 성능을 보이며 널리 활용되고 있지만, 충분한 양의 학습 데이터가 확보되지 않으면 트랜스포머를 구성하고 있는 매개변수의 학습이 충분히 이루어지지 않아서 양질의 요약문을 생성하기 어렵다는 한계를 갖는다. 따라서 본 연구는 소량의 학습 데이터가 주어진 상황에서도 양질의 요약문을 생성하기 위해, 한국어 사전학습 언어 모델인 KoBERT의 일부 요소를 추출하여 트랜스포머 기반의 추상 요약 모델에 적용하는 문서 요약 방안을 제시한다. 제안 방법론의 우수성을 검증하기 위해 Dacon의 한국어 문서 생성 요약 데이터 42,803건에 대한 요약 실험을 수행한 결과, 제안 방법론이 비교 방법론에 비해 요약 품질을 평가하는 지표인 ROUGE 기준으로 우수한 성능을 보임을 확인하였다.

핵심주제어: 딥러닝, 자동 문서 요약, 트랜스포머, 사전학습 언어 모델

논문접수일: 2021년 09월 27일 수정일: 2021년 12월 01일 게재확정일: 2021년 12월 06일
† 이 논문은 AI 양재 허브의 “고성능 컴퓨팅 인프라 지원사업”의 지원을 받아 수행된 연구임.
* 국민대학교 비즈니스IT전문대학원 석사과정, dmltjr802@kookmin.ac.kr
** 국민대학교 비즈니스IT전문대학원 교수, ngkim@kookmin.ac.kr

www.kci.go.kr

Ⅰ. 서 론

텍스트는 다양한 정보를 쉽게 표현하고 전달할 수 있는 대표적인 수단으로 사용되어 왔으며, 최근 정보 전달 기기가 대중화됨에 따라 더욱 많은 양의 텍스트 데이터가 생산 및 유통되고 있다. 특히, 소셜 미디어(Social Media)의 등장으로 정보 생산자는 정보 이용자에게 손쉽게 정보를 전달할 수 있게 되었고, 이는 오늘날 방대한 양의 텍스트 데이터가 온라인상에서 활발하게 유통되는 계기가 되었다. 이로 인해 온라인상에 유통되는 텍스트 정보를 활용하여, 특정 집단의 동향 및 성향을 파악하여 통찰을 도출하는 시도가 이루어졌다(김정수와 이석준, 2015 ; 정해강과 김남규, 2018 ; 윤성식 외, 2021). 한편, 정보 이용자가 방대한 정보로부터 필요한 정보만을 추려내는 작업은 더욱 어렵게 되었으며, 이는 정보의 손실을 최소화하면서 방대한 텍스트 정보를 자동으로 적은 양으로 축약하려는 시도, 즉 자동 텍스트 요약(Automatic Text Summarization) 연구가 등장하는 배경이 되었다.

자동 텍스트 요약 연구는 요약을 생성하는 방식에 따라 크게 추출 요약(Extractive Summarization) 접근과 추상 요약(Abstractive Summarization) 접근으로 구분된다(Eduard, 2015; Venkat, 2018). 추출 요약은 원문을 이루고 있는 문장 중 어떤 문장이 요약문으로서 의미가 있는지를 점수화하고, 이를 기반으로 주요 문장을 발췌하는 요약 방법이다. 이렇게 생성된 요약문은 원문으로부터 문장 단위로 발췌되었기 때문에, 문법적 오류가 적고 문장 내 표현이 자연스럽다는 장점이 있다. 따라서 빠르게 서비스화에 성공했으며, 대표적인 예로 네이버 뉴스의 요약봇 서비스(김현아, 2017), 다음 뉴스의 자동 요약 서비스(장윤희, 2016) 연합뉴스의 인공지능 기사요약 서비스(서명덕, 2021) 등이 있다. 하지만 이 방식은 원문 내에 존재하는 문장만 요약문에 포함될 수 있기 때문에 원본 문서에 없는 표현은 사용이 불가능하고, 문장간 연결이 어색할 수 있다는 단점을 갖는다.

이와 달리 추상 요약은 요약문을 생성하기 위해 원문에 존재하는 텍스트를 사용하되, 요약문 작성 과정에서 어휘를 재구성 및 변환하여 원문에 존재하지 않는 새로운 텍스트 시퀀스(Sequence)를 생성한다. 따라서 추상 요약의 요약문은 새로운 표현을 풍부하게 사용할 수 있으며, 이로 인해 마치 사람이 요약한 것과 같은 요약문을 생성할 수 있다. 이러한 장점에도 불구하고 전통적인 추상 요약 연구는 문법적으로 오류가 많거나 문맥이 자연스럽지 않은 텍스트 시퀀스를 생성하는 경우가 많다는 한계로 인해 현업에서 쉽게 적용되지 못했다.

추상요약의 이러한 한계는 신경망 기반의 Seq 2Seq(Sequence to Sequence) 모델(Sutskever et al., 2014)과 어텐션 메커니즘(Attention Mechanism)(Bahdanau et al., 2014)이 제안되고, 이로 인해 텍스트 사이의 관계 파악 수준이 향상됨에 따라 상당한 개선이 이루어졌다. 한편 텍스트 시퀀스가 길어짐에 따라 신경망이 텍스트 시퀀스 사이의 문맥적인 정보를 제대로 학습하지 못하는 장기 의존성 문제가 여전히 제기되었으나, 최근 트랜스포머(Transformer) 모델(Vaswani et al., 2017)이 학습 구조를 획기적으로 개선하면서 이러한 한계를 극복하였다. 이후 추상 요약을 다루는 대부분의 연구는 트랜스포머를 기반으로 이루어지고 있으며(Sanjabi, 2018; Deaton et al., 2019), 현재 텍스트 요약 기술의 SOTA(State of the Art)를 달성하고 있다(Xu et al., 2020).

하지만 트랜스포머에 기반한 텍스트 요약 모델은 일반적으로 매우 많은 매개변수로 구성되므로, 매개변수 갱신을 위해 상당히 많은 양의 데이터와 학습 시간 및 자원이 필요하다(Reid et al., 2020). 이는 자연어에 대한 사전 지식 없이 주어진 원문에만 의존하여 요약문 생성을 위한 학습과 문맥 정보 파악을 위한 학습을 동시에 수행하는 모델의 특성에 기인한 것으로, 이를 개선하기 위해 시퀀스 생성을 사

www.kci.go.kr

<표 1> 추출 요약 접근법과 추상 요약 접근법 비교

접근법	추출 요약 접근법 Extractive Summarization Approach	추상 요약 접근법 Abstractive Summarization Approach
원리	· 원문을 구성하고 있는 문장 중 주요 문장을 · 발췌하고 이를 조합하여 요약문을 생성하는 방식	· 원문을 구성하고 있는 텍스트를 사용하되, · 어휘를 재구성 및 변환하여 새로운 텍스트 시퀀스를 생성하는 방식
장점	· 원문으로부터 발췌된 문장을 사용하므로 문법적 오류가 적음	· 풍부한 표현의 요약문을 생성할 수 있음
단점	· 조합된 문장들 사이의 연결이 어색할 수 있음 · 원문에 나타난 문장만 요약문에서 표현할 수 있음	· 문법적 오류가 있거나 문맥이 부자연스러운 요약문을 생성하는 경우가 많음
전통적인 기법	· 통계 기반 접근법 · 그래프 랭킹 알고리즘 기반 접근법	· 트리 기반 접근법 · 규칙 기반 접근법 · 템플릿 기반 접근법
최근 이슈	· 원문에서 적절한 문장을 발췌하기 위한 성능 개선	· 사람이 작성한 것과 같이 자연스러운 요약문을 생성하는 것에 주목 · 소량의 데이터로부터 효과적으로 양질의 요약문을 생성

전학습하고 전통적인 트랜스포머 모델을 구조적으로 변형하는 연구(Khandelwal et al., 2019)가 제안되었으나 이는 요약 학습과는 별개로 별도의 사전학습과 이를 위한 텍스트 데이터를 요구한다는 한계가 있다.

따라서 본 연구는 추가적인 사전학습 없이 많은 양의 요약 학습 데이터가 주어지지 않은 상황에서도 트랜스포머 모델이 양질의 요약문을 생성할 수 있도록, 한국어 사전학습 언어 모델(Pre-trained Language Model)인 KoBERT(SKT Open Source, 2021)의 일부 요소를 기존의 트랜스포머 기반 추상 요약 모델에 적용하는 문서 요약 방안을 제시한다. 또한, 제안 방법론의 성능을 검증하기 위해 Dacon에서 제공한 한국어 문서 생성 요약 데이터 42,803건에 대한 실험을 수행하여, 학습 데이터 양의 변화에 따른 기존 방법론과 제안 방법론의 요약 품질을 비교한다.

본 논문의 이후 구성은 다음과 같다. 우선 2장에서는 본 연구와 관련된 선행 연구들을 소개하고, 3장에서는 본 연구의 전체적인 개요와 방법론을 제시한다. 다음으로 4장에서는 제안 방법론을 실제 데이터에 적용하여 추상 요약을 수행한 결과를 소개하고, 마지막 장인 5장에서는 본 연구의 기여 및 한계, 그리고 후속 연구 방향을 논의한다.

II. 이론적 배경

1. 자동 텍스트 요약

자동 텍스트 요약은 내용의 주요 정보와 전반적인 의미를 보존하면서 간결하고 자연스러운 요약문을 생성하는 과제(Allahyari, 2017)로, 요약을 생성하는 방식에 따라 <표 1>과 같이 크게 추출 요약 접근과 추상 요약 접근으로 구분된다. 추출 요약은 원문과 가장 관련 있는 문장들을 선택 또는 발췌하고 이를 조합하여 요약문을 생성하는 방법이다(Gambhir and Gupta, 2017). 추출 요약은 원문을 이

www.kci.go.kr

루고 있는 문장들 중 요약문에 포함될 주요 문장을 발췌하는 것이 핵심이며, 이를 위해 언어학적 통계 정보와 그래프 랭킹 알고리즘을 이용한 연구(Mihalcea, 2004), 원문을 구성하는 문장들 중 요약문에 포함될 문장을 분류 및 선택하여 요약문을 생성한 연구(Nallapati et al., 2016) 등이 수행된 바 있다.

한편, 추상 요약은 언어학적 정보를 이용하여 원문을 해석하고 이를 토대로 정보를 간결하게 압축하여 요약문을 생성하는 방법으로, 전통적인 추상 요약은 트리 기반(Tree-based) 방법론, 규칙 기반(Rule-based) 방법론 등과 같은 구조화된 언어학적 정보를 이용하여 요약문을 생성한다(Khan and Salim, 2014). 이러한 특징으로 인해 추상 요약으로 생성된 요약문은 새로운 어휘를 포함하거나 새로운 시퀀스를 생성할 수 있어, 풍부한 표현의 요약문을 생성할 수 있다는 장점이 있다. 하지만 전통적인 추상 요약은 모든 언어학적 관계를 명확히 구조화하기 어려워, 전통적인 방법론으로 생성한 요약문은 문법적 오류를 포함하거나 요약문의 표현이 부자연스럽다는 한계를 갖는다.

이러한 추상 요약의 한계는 신경망 기반의 방법론을 적용하면서 크게 개선되었는데, 특히 기계 번역 과제에서 큰 성과를 이룬 Seq2Seq 모델과 어텐션 메커니즘 모델의 구조를 추상 요약에 적용하여 양질의 요약문을 생성할 수 있었다(Rush et al., 2015). 이러한 발전으로 텍스트 사이의 관계 파악 수준이 크게 향상되어 모델이 원문을 이해하고 요약문을 생성하는 능력이 대폭 개선되었으며, 이를 바탕으로 신경망 기반의 추상 요약을 수행하기 위한 연구가 더욱 활발히 이루어지고 있다. 신경망 기반의 추상 요약을 개선한 연구로는 언어학적 정보와 어텐션 기반의 순환 신경망(Recurrent Neural Network, RNN)을 이용한 연구(Nallapati et al., 2016), 주요 단어를 요약문에 반영하기 위하여 원문으로부터 단어를 복사하는 복사 메커니즘(Copy Mechanism) 접근법을 추상 요약에 적용한 연구(Gu et al., 2016), 어텐션 메커니즘이 일부 어텐션 시점에 반복적으로 집중하는 문제를 예방하기 위하여 커버리지 메커니즘(Coverage Mechanism) 접근법을 추상 요약에 적용한 연구(See et al., 2017) 등이 있다.

2. 트랜스포머 기반 문서 요약

순환 신경망은 주어진 텍스트 사이의 관계를 시퀀스 정보를 활용하여 효과적으로 파악할 수 있다는 점에서 다양한 자연어 처리 과제에 활용되고 있다. 하지만 텍스트 시퀀스가 길어짐에 따라 순환 신경망이 텍스트 사이의 문맥 정보를 제대로 학습하지 못하는 장기 의존성 문제를 갖는다는 한계가 제기되면서 이를 개선하려는 연구가 이루어졌다. 순환 신경망의 장기 의존성 문제를 개선하기 위한 연구로는 시퀀스 정보를 제어하는 별도의 셀(Cell) 또는 게이트(Gate) 유닛을 추가한 연구(Hochreiter and Schmidhuber, 1997; Cho et al., 2014), 디코더(Decoder)의 매 시점 마다 인코더(Encoder)의 문맥 정보를 참조하는 연구(Bahdanau et al., 2014) 등이 있다. 그러나 순환 신경망 기반의 인코더-디코더 구조는 인코더에서 입력 시퀀스를 하나의 벡터 표현으로 압축하는 과정에서 정보 손실이 발생한다는 구조적인 한계를 가지므로 장기 의존성 문제는 여전히 근본적으로 해결되지 못했다.

순환 신경망 기반 인코더-디코더의 구조적 한계인 장기 의존성 문제는 순차적인 입력을 필요로 하지 않는 셀프 어텐션(Self-Attention) 계층으로 구성된 트랜스포머가 제안되면서 개선되었다(Vaswani et al., 2017). 특히, 셀프 어텐션 계층은 어텐션 연산의 병렬화를 위하여 입력된 텍스트를 여러 표현으로 구분하여 연산을 수행하게 되는데, 이때 다양한 관점으로 언어학적 관계를 구조화하므로 복잡한 문맥 정보를 학습할 수 있다. 이러한 장점으로 추상 요약

www.kci.go.kr

과제에서도 트랜스포머를 적용하려는 시도가 이어졌으며, 일례로 Sanjabi(2018)가 추상 요약 과제에 트랜스포머 모델을 성공적으로 적용하면서 추상 요약에 대한 트랜스포머의 유용성을 보여주었다. 또한 Deaton et al.(2019)은 커버리지 메커니즘 접근법과 셀프 어텐션의 분포를 이용하여 원문으로부터 단어를 복사하는 PG-Net(Pointer-Generator Network) 접근법을 트랜스포머 기반의 추상 요약에 적용하였고. Xu et al.(2020)은 트랜스포머 기반의 추상 요약 모델이 원문의 주요한 단어를 복사할 수 있도록 어텐션 분포의 중심성을 고려한 복사 메커니즘 접근법을 적용하였다.

3. 사전학습 언어 모델

트랜스포머 모델이 기계 번역 및 추상 요약과 같은 자연어 생성 과제에서 우수한 성능을 보임에 따라, 관련 분야의 연구자들은 트랜스포머의 자연어 이해 능력에 집중하게 되었다. 트랜스포머 구조를 활용하여 많은 양의 텍스트 데이터로부터 언어학적 문맥 정보를 학습한 BERT, GPT, GPT-2는 자연어 처리 분야에 존재하는 여러 벤치마크 데이터셋에 대하여 높은 수준의 성능을 달성하면서(Devlin et al., 2018; Radford et al., 2018; Radford et al., 2019), 트랜스포머를 기반으로 한 사전학습 언어 모델의 우수성을 보였다. 특히, BERT는 트랜스포머의 인코더를 활용하여 텍스트 데이터로부터 효과적으로 문맥 정보를 학습하도록 고안된 MLM(Masked Language Model)과 NSP(Next Sentence Prediction)를 학습함으로써, 입력된 텍스트 시퀀스 사이의 복잡한 문맥 정보를 잘 이해된 표현으로 생성할 수 있다. 이러한 BERT의 장점으로 인해, 최근 추상 요약 과제에 BERT를 적용하려는 시도가 이어지고 있다.

Rothe et al.(2020)은 BERT, GPT-2 그리고 RoBERTa(Liu et al., 2019)를 전통적인 트랜스포머의 인코더와 디코더에 다양하게 적용하여, 추상 요약 과제에 대한 사전학습 언어 모델의 효과성을 보여주었다. Goodman et al.(2019)은 추상 요약 과제에 BERT를 효과적으로 적용하기 위해 짧은 형태의 요약문을 생성하는 학습을 수행한 뒤, 이후 긴 형태의 요약문을 생성하는 학습을 뒤이어 수행하는 다단계 학습 방법론을 제안하였다. Liu and Lapata (2019)는 추출적 요약 학습을 수행한 BERT와 전통적인 트랜스포머의 디코더를 결합한 요약 모델을 추상 요약 과제에 적용하여 우수한 요약 성능을 달성하였다. 이처럼 추상 요약 과제에 대한 전통적인 트랜스포머와 트랜스포머 기반의 사전학습 언어 모델의 성공적인 적용에도 불구하고, 트랜스포머 기반의 요약 모델은 매우 많은 수의 매개변수 갱신을 위해 상당히 많은 양의 데이터와 학습 시간 및 자원을 필요로 한다는 한계를 갖는다. 이러한 한계는 요약문 학습에 활용할 수 있는 데이터가 상대적으로 적은 양의 한국어 문서에 대해, 추상 요약 과제에 트랜스포머 모델을 적용할 때 더욱 큰 부작용으로 나타나게 된다.

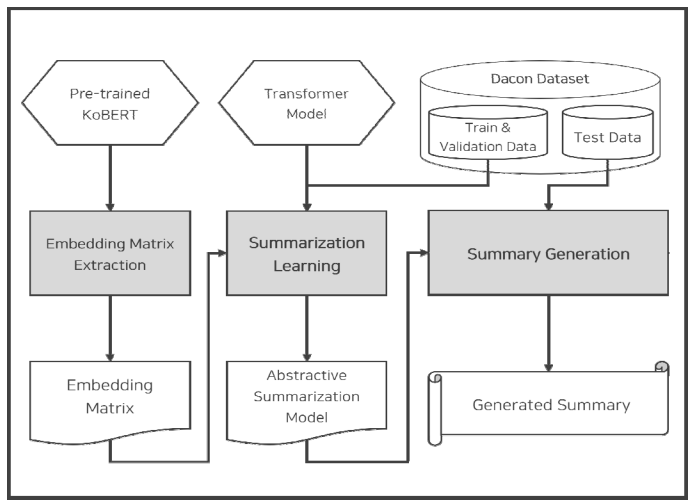
따라서 본 연구에서는 소량의 학습 데이터가 주어진 상황에서도 양질의 요약문을 생성하기 위해, 한국어 사전학습 언어 모델인 KoBERT의 일부 요소를 추출하여 트랜스포머 기반의 추상 요약 모델에 적용하는 문서 요약 방안을 제시한다. 또한, 주어진 요약 데이터의 양이 트랜스포머 기반의 추상 요약 모델의 성능에 미치는 영향을 분석하고자 한다.

Ⅲ. 제안 방법론

1. 연구모형

본 절에서는 트랜스포머 기반 요약 모델이 소량의 데이터가 주어진 환경에서도 양질의 요약문을 생성할 수 있도록, 한국어 사전학습 언어 모델인

www.kci.go.kr



<그림 1> 연구 모형 개요

KoBERT의 일부 요소를 트랜스포머에 적용하는 방법론을 제안한다(그림 1).

<그림 1>의 좌측 흐름은 대규모의 한국어 텍스트 문서로부터 MLM과 NSP를 수행하여 한국어의 복잡한 문맥 정보를 학습한 KoBERT의 임베딩 행렬(Embedding Matrix)를 선택적으로 추출하는 과정이다. 추출된 임베딩 행렬은 요약 학습을 수행할 트랜스포머의 임베딩 행렬을 대체하며, Dacon 데이터로부터 훈련 데이터와 검증 데이터를 구분하여 요약 학습을 진행한다. 트랜스포머 모델은 KoBERT의 언어학적 지식에 힘입어 적은 양의 데이터에 대해서도 효과적으로 요약문을 생성할 수 있게 된다. 학습이 완료된 요약 모델은 우측 흐름과 같이 시험 데이터에 대한 추론을 통해 요약문을 생성한다.

생성된 요약문에 대한 품질은 대표적인 평가 지표인 ROUGE(Recall-Oriented Understudy for Gisting Evaluation)를 이용하여 평가하였으며(Lin, 2004), 평가에는 Dacon 데이터 중 요약 학습에 사용되지 않은 데이터를 활용하였다. 전체 과정을 구성하는 단계별 설명은 이후 절에서 자세히 다루며, 실제 데이터에 대한 실험 결과는 4장에서 소개한다.

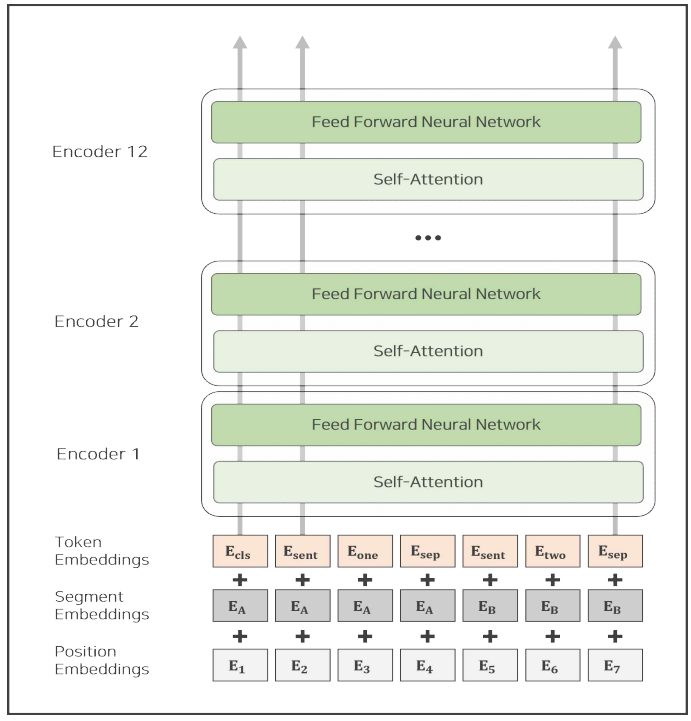
2. 임베딩 행렬 추출

본 절에서는 사전학습 언어 모델인 KoBERT의 구성을 소개하고, KoBERT로부터 선택적으로 임베딩 행렬을 추출하는 방안을 구체적으로 다룬다.

KoBERT는 트랜스포머의 인코더 구조를 활용하여 한국어 위키피디아와 뉴스 등으로부터 수집한 약 500만 개의 문장에 대해 한국어 문맥 정보를 학습하였다. 이렇게 학습한 문맥 정보를 효과적으로 보존하기 위해 KoBERT는 전통적인 트랜스포머 모델과 비교하여 더 큰 은닉층 크기와 더 많은 어텐션 헤드 및 인코더 계층을 갖는다. 또한, KoBERT는 기존의 트랜스포머와는 상이한 형태의 입력 계층을 갖는데, 구체적인 구조는 <그림 2>와 같다.

KoBERT는 총 13개의 계층, 즉 12개의 인코더 계층과 1개의 입력 계층으로 구성되어 있다. 특히, 입력 계층은 3개의 임베딩 계층으로 이루어져 있으며, 각각 단어의 벡터를 출력하는 토큰 임베딩, 문서 내

www.kci.go.kr



<그림 2> KoBERT의 내부 구조

오늘 오전부터 충부지방에 많은 비가 쏟아 질 예정이다.
이번 비는 점차 확산되어 오후에 전국적으로 내릴 전망이다.

Segment A		Segment B	
Position	Token	Position	Token
1	[CLS]	16	_이번
2	_오늘	17	_비
3	_오전	18	는
4	부터	19	점차
5	충	20	_확산
6	부	21	되어
7	지방	22	_오후
8	에	23	에
9	_많은	24	_전국
10	비가	25	적으로
11	_쏟아	26	_내
12	_질	27	릴
13	_예정이다.	28	_전망이다
14	.	29	.
15	[SEP]	30	[SEP]

단어 '_비 ' 에 대한 KoBERT의 임베딩 벡터값

차원	Dim 1	Dim 2	Dim 3	…	Dim 767	Dim 768
토큰 임베딩	8.8519	2.0480	-2.4341	…	-8.2313	4.5970
세그먼트 임베딩	6.5819	-2.7638	-1.6106	…	-8.9667	6.4429
포지션 임베딩	-2.4195	1.9379	2.3595	…	1.0530	-8.8045

<그림 3> KoBERT 입력 계층의 벡터 표현 예시

www.kci.go.kr

에서 문장의 위치 벡터를 출력하는 세그먼트 임베딩 그리고 문서 내에서 단어의 위치 벡터를 출력하는 포지션 임베딩으로 구성되어 있다. 3개의 임베딩 계층은 각 목적에 따라 입력된 문장 또는 문서에 대하여 <그림 3>과 같이 동일한 차원을 갖는 벡터를 생성한다.

<그림 3>은 KoBERT의 입력 계층이 입력된 문장에 대한 벡터를 생성하는 가상의 예시를 나타낸다. 각 단어는 고유의 단어 표현뿐 아니라, 문서 내의 위치와 해당 단어가 속한 문장의 위치를 함께 고려하여 표현된다. 즉, KoBERT의 입력 계층은 동일한 단어 '_비'에 대해서도 해당 단어가 출현한 위치에 따라 상이한 벡터값을 출력한다.

KoBERT는 입력 계층에서 표현된 언어학적 정보를 12개의 인코더 계층에 전달하며, 인코더 계층은 주어진 언어학적 정보를 토대로 복잡한 문맥 관계를 학습한다. 이 과정에서 KoBERT는 인코더 계층으로부터 학습한 문맥 관계를 다시 입력 계층에 역전파하여, 입력 계층이 언어학적 정보를 이전보다 더욱 잘 나타낼 수 있도록 돕는다. 즉, 이러한 학습 과정이 반복됨에 따라 입력 계층에서 단어의 고유 표현을 나타내는 토큰 벡터의 값도 <그림 4>와 같이 갱신이 이루어진다. 이는 사전학습 과정에서 인코더 계층으로부터 전달받은 문맥 정보를 활용하여, 토큰 벡터의 값을 생성하기 위한 임베딩 행렬 자체를 갱신함을 의미한다. 본 연구에서는 이렇게 갱신된 KoBERT의 토큰 임베딩 행렬을 추출하여, 요약 학습을 수행하는 트랜스포머의 임베딩 행렬을 대체함으로써 KoBERT의 지식을 습득하는 방안을 제안한다.

3. KoBERT의 토큰 임베딩을 사용한 트랜스포머 기반 요약 모델 생성

전통적인 트랜스포머는 자연어에 대한 사전 지식 없이 원문에 의존하여 요약 학습을 수행하므로, 방

▪ 사전학습 이전의 KoBERT의 토큰 임베딩 행렬 예시

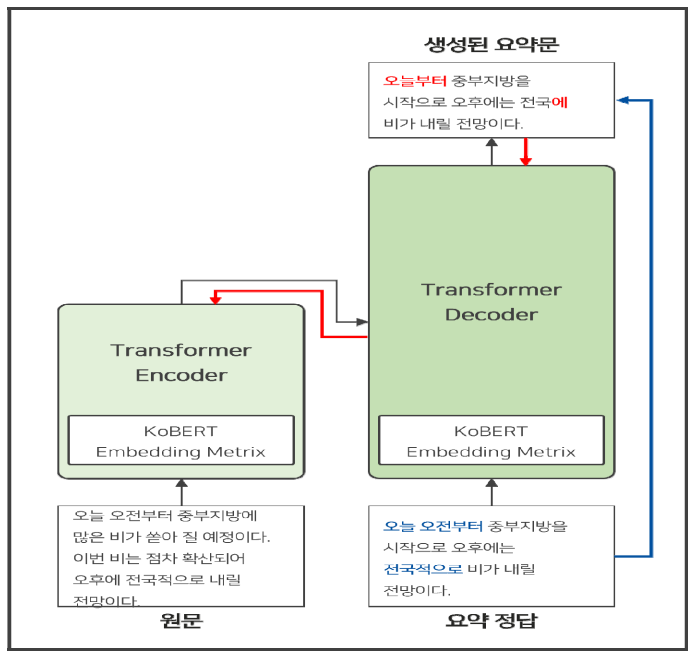
Index	Token	차원			
		Dim 1	Dim 2	…	Dim 768
0	[UNK]	1.9368	3.0275	…	2.9537
1	[PAD]	0.0396	-0.0460	…	0.0082
⋮					
2514	_비	-4.2495	8.3066	…	-3.7796
⋮					
8001	힙	8.2249	-3.9528	…	-2.0968

▪ 사전학습 이후의 KoBERT의 토큰 임베딩 행렬 예시

Index	Token	차원			
		Dim 1	Dim 2	…	Dim 768
0	[UNK]	-8.6276	1.5278	…	-1.9890
1	[PAD]	1.3682	2.7340	…	-7.2012
⋮					
2514	_비	8.8519	2.0480	…	4.5970
⋮					
8001	힙	0.034	-0.0131	…	0.0057

<그림 4> 사전학습에 의한 토큰 임베딩 값의 변화

www.kci.go.kr



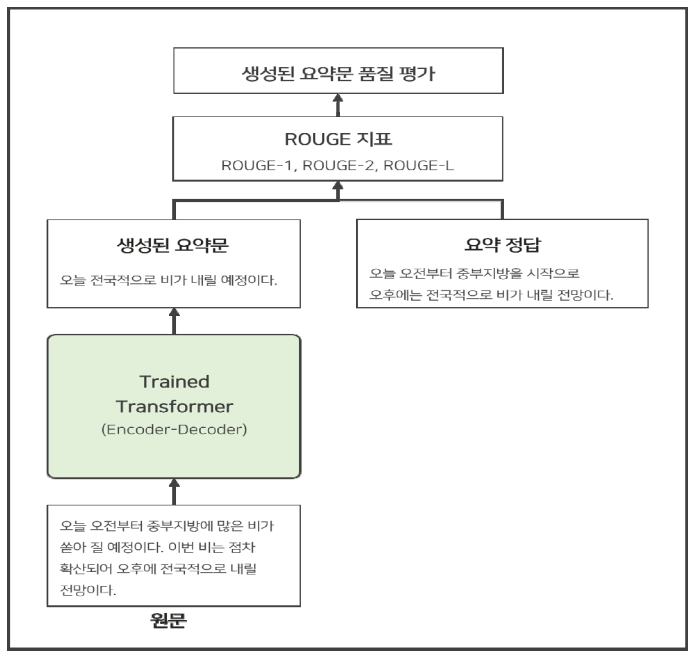
<그림 5> 트랜스포머 기반 요약 모델의 학습 과정

대한 양의 매개변수를 적절히 갱신하기 위해 많은 양의 데이터를 필요로 한다. 따라서 본 연구에서는 3.2절에서 추출한 KoBERT의 토큰 임베딩 행렬을 트랜스포머의 토큰 임베딩 행렬로 대체하여, 트랜스포머가 적은 양의 데이터만으로도 매개변수를 효과적으로 갱신할 수 있는 방안을 제시한다. 구체적으로 KoBERT를 통해 학습한 단어 수준의 지식이 트랜스포머의 문서를 이해하는 인코더와 요약문을 생성하는 디코더 양 쪽에 모두 전달될 수 있도록 하기 위해, KoBERT의 토큰 임베딩 행렬을 트랜스포머의 인코더 임베딩과 디코더 임베딩 행렬에 모두 적용한다.

임베딩 행렬이 적용된 트랜스포머가 요약 학습을 수행하는 과정은 <그림 5>와 같다. 우선, KoBERT의 임베딩 행렬이 입력된 원문에 대하여 단어 벡터를 생성하고, 생성된 단어 벡터에 시퀀스 정보를 추가하여 트랜스포머의 인코더 계층에 전달한다. 인코더 계층은 입력받은 벡터 표현으로부터 문맥 정보를 파악하고 이를 다시 구조화하여 트랜스포머의 디코더 계층에 전달한다. 디코더 계층은 인코더로부터 전달받은 정보를 통해 요약문을 생성하고, 생성한 요약문과 요약 정답의 차이를 비교하는 학습을 수행하여 요약문 생성 모델을 생성한다. 위의 과정을 통해 생성한 트랜스포머 기반 요약 모델을 사용하여 자동으로 요약문을 생성하고, 생성된 요약문의 품질을 평가하는 과정은 <그림 6>과 같다.

<그림 6>에서 학습이 완료된 트랜스포머는 요약 정답 없이 원문만을 입력으로 받아 요약문을 자동으로 생성함을 알 수 있다. 즉, 입력된 문서를 벡터로 구조화하고, 이미 학습한 문맥 정보를 이용하여 구조화된 문서 벡터에 대응하는 요약을 생성한다. 이렇게 생성된 요약의 품질은 사람이 작성한 요약 정답과의 정량적 비교를 통해 측정 가능하며, 다양한 평가 지표 중 ROUGE가 가장 널리 사용된다. 본 연구에서는 요약 품질을 다양하게 평가하기 위해 ROUGE-1, ROUGE-2, 그리고 ROUGE-L의 세 가

www.kci.go.kr



<그림 6> 요약문의 생성 및 품질 평가

<표 2> 데이터 구성 환경

Dacon Dataset				
Train			Validation	Test
100%	50%	20%		
38,522	19,261	7,704	2,140	2,141

지 지표를 사용한다.

Ⅳ.실 험

1. 실험 개요

본 연구의 실험은 Dacon에서 제공한 한국어 문서 생성요약 데이터셋을 활용하여 수행하였으며, 기존의 요약 데이터셋인 CNN-Daily Mail, BBC XSum의 데이터 구분 비율을 참조하여 <표 2>와 같이 데이터의 역할을 구분하였다.

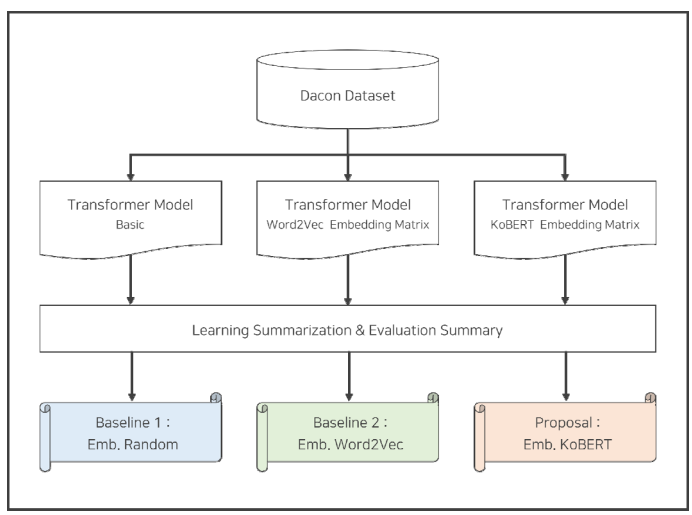
구체적으로 총 42,803건의 데이터를 우선 학습용 데이터 38,522건, 검증용 데이터 2,140건, 그리고 테스트 데이터 2,141건으로 각각 90:5:5의 비율로 구분하였다. 또한, 소량의 학습 데이터가 주어진 상황에서 나타나는 요약 품질의 하락 수준을 평가하기 위해, 학습용 데이터 38,522건(100%)을 모두 학습에 사용한 실험, 학습용 데이터 중 19,261건(50%)만 학습에 사용한 실험, 그리고 7,704건(20%)만 학습에 사용한 실험을 수행하여 그 결과를 비교하였다.

본 연구의 실험 환경은 <표 3>과 같이 Python 3.7과 딥러닝 프레임워크인 Tensorflow, Pytorch를

www.kci.go.kr

<표 3> 실험 환경 개요

실험 환경		
하드웨어	CPU	8 core
	GPU	Tesla P40 * 2ea
	Memory	60GB
언어	Python	3.7
딥러닝 프레임워크	Tensorflow	2.3.0
	Pytorch	1.9.0



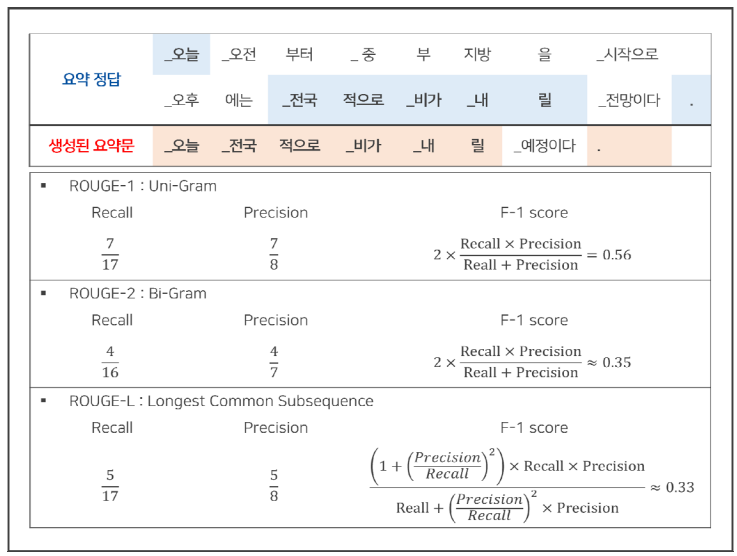
<그림 7> 실험 모형

통해 구축하였으며, CPU 8 Core와 Tesla P40 GPU 등의 하드웨어 자원이 사용되었다.

본 연구의 실험 모형은 <그림 7>과 같이 구성하였으며, 제안 방법론의 우수성을 평가하기 위하여 두 가지 기준 모델과의 요약 품질 비교 실험을 진행하였다. 첫 번째 비교 모델(Emb. Random)은 전통적인 트랜스포머 기반 요약 모델로, 임베딩 행렬의 초기값은 임의의 값으로 설정되어 있다. 이는 Emb. Random 모델은 자연어에 대한 어떠한 사전 지식도 없이 주어진 원문에만 의존하여 요약 학습을 수행함을 의미한다. 두 번째 비교 모델(Emb. Word2Vec)은 주변 단어의 문맥 정보를 학습하여 어휘의 벡터값을 산출하는 알고리즘인 Word2Vec을(Mikolov, 2013) 사용하여 트랜스포머 임베딩 행렬의 초기값을 설정한 모델이다. 즉 Emb. Word2Vec 모델은 Word2Vec을 통해 자연어에 대한 지식을 습득한 상황에서 요약 학습을 수행한다. 마지막 Emb. KoBERT는 본 연구에서 제안하는 요약 모델로, KoBERT의 토큰 임베딩을 통해 자연어에 대한 지식을 전달한다.

본 실험에서는 <그림 7>에 따라 각 모델을 통해 요약문을 생성한 뒤, 각 모델이 생성한 요약문의 품질을 대표적인 요약 평가 지표인 ROUGE를 사용하여 평가했다. ROUGE는 비교 대상에 따라 더욱 세분화되는데, 대표적으로 ROUGE-N과 ROUGE-L이 널리 사용된다. 본 실험에서는 ROUGE-N 기반의

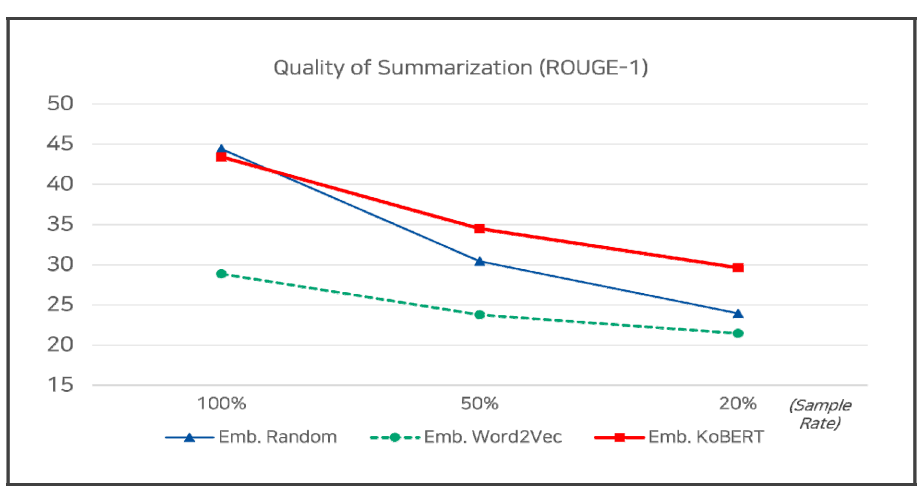
www.kci.go.kr



<그림 8> ROUGE의 평가 방법 예시

ROUGE-1, ROUGE-2 그리고 ROUGE-L를 활용하여 요약문의 품질을 평가하였으며, 평가에 사용된 ROUGE 지표의 산출 방식은 <그림 8>과 같다.

ROUGE 지표는 사람이 작성한 요약 정답과 요약 모델이 생성한 요약문 사이에 단어가 일치하는 정도를 파악하여 요약 품질을 평가한다. 먼저, ROUGE-N은 일치하는 단어의 단위(N-Gram)에 따라 다양한 수준으로 구현되며, 대표적으로 단어의 개별 단위(Uni-Gram)로 일치 정도를 평가하는 ROUGE-1과 연속된 두 개의 단어 단위(Bi-Gram)로 일치 정도를 평가하는 ROUGE-2가 사용된다. ROUGE-N의 산출에는 정밀도(Precision)와 재현율



<그림 9> 모델별 요약 품질 (ROUGE-1(F1-Score))

www.kci.go.kr

(Recall)이 사용되며, 정밀도는 생성된 요약문 관점에서의 일치 정도를, 재현율은 요약 정답 관점에서의 일치 정도를 측정한다. 한편, ROUGE-L은 두 문장이 공통으로 갖는 서브시퀀스(Subsequence)의 길이로 요약문의 품질을 평가한다. 예를 들어 <그림 8>에서 요약 정답의 길이는 17, 모델이 생성한 요약문의 길이는 8이며, 두 문장이 공통으로 갖는 서브시퀀스 "_전국 / 적으로 / _비가 / _내 / 릴"의 길이는 5이다. 따라서 $ROUGE\text{-}L_{(Recall)}$은 5/17이며, $ROUGE\text{-}L_{(Precision)}$은 5/8가 된다.

본 실험에서는 ROUGE-1, ROUGE-2 그리고 ROUGE-L의 지표 각각에 대해 정밀도, 재현율, 그리고 F1-Score를 모두 측정하여 각 모델이 생성한 요약문의 품질을 평가한다. 구체적으로는 학습용 데이터로 모델을 학습하고 검증용 데이터로부터 손실값이 가장 낮은 에폭(Epoch)을 선정하였으며, 이때의 모델을 테스트 데이터에 적용하여 생성한 요약문에 대해 ROUGE 지표를 산출하였다.

2. 실험 결과

본 절에서는 4.1절의 설계에 따라 수행한 실험의 결과를 분석한다. <그림 9>는 학습 데이터의 크기에 따른 각 모델들의 $ROUGE\text{-}1_{(F1\text{-}Score)}$ 값의 변화를 도식화한 그래프이다.

<그림 9>는 트랜스포머만 사용한 전통적인 요약 모델(Emb. Random), Word2Vec을 사용하여 트랜스포머 임베딩 행렬의 초기값을 설정한 모델(Emb. Word2Vec), 그리고 본 연구에서 제안하는 모델인 KoBERT를 사용하여 트랜스포머 임베딩 행렬의 초기값을 설정한 모델(Emb. KoBERT)의 $ROUGE\text{-}1_{(F1\text{-}Score)}$ 측면에서의 요약 품질을 나타낸다. 세 가지 모델 모두에서 학습 데이터의 크기가 작을수록 요약 성능이 저하되는 것을 확인할 수 있다. 이러한 양상은 ROUGE-2, 그리고 ROUGE-L의 지표를 활용한 분석에서도 공통적으로 나타났으며, 그 결과는 <표 4>를 통해 확인할 수 있다.

<그림 9>와 <표 4>에서 Emb. Word2Vec 모델은 학습 데이터 사용 비율과 무관하게 가장 낮은 성능을 나타냈으며, Emb. Random과 Emb. KoBERT는 학습 데이터 사용 비율에 따라 성능 순위가 역전됨을 알 수 있다. 구체적으로 학습 데이터의 양이 충분한 경우에는 자연어에 대한 사전 지식 없이 원문에만 의존하여 요약 학습을 수행한 Emb. Random 모델의 성능이 가장 우수하게 나타났으나, 학습 데이터의 양이 줄어들수록 Emb. Random 모델의 성능은 급격하게 하락하였다. 이와 달리 제안 모델인 Emb. KoBERT 모델은 학습 데이터 양의 감소에 따른 성능 저하 현상이 매우 완만하게 나타났으며, 이로 인해 적은 양의 학습 데이터가 사용된

<표 4> 평가지표별 모델 성능 비교

평가 지표	요약 모델	학습 데이터 사용 비율		
		100%	50%	20%
ROUGE-1	Emb. Random	**44.39**	30.39	23.92
	Emb. Word2Vec	28.87	23.75	21.42
	Emb. KoBERT	43.41	**34.46**	**29.6**
ROUGE-2	Emb. Random	**27**	8.86	4.8
	Emb. Word2Vec	7.32	4.94	3.34
	Emb. KoBERT	24.43	**10.47**	**6.99**
ROUGE-L	Emb. Random	**31.64**	18.92	15.02
	Emb. Word2Vec	17.59	14.8	12.81
	Emb. KoBERT	29.25	**20.26**	**16.57**

www.kci.go.kr

50%, 20% 실험에서는 Emb. KoBERT의 요약 성능이 가장 우수하게 나타났다.

본 절에서는 세 가지 요약 모델의 성능 비교와 함께, 주어진 요약 데이터의 양이 트랜스포머 기반 추상 요약 모델의 성능에 미치는 영향을 분석하였다. 실험을 통해 제안 모델이 소량의 학습 데이터가 주어진 상황에서 기존의 요약 모델에 비해 양질의 요약문을 생성할 수 있음을 확인하였다. 이러한 결과는 방대한 양의 텍스트 데이터로부터 문맥 정보를 학습한 KoBERT의 임베딩 행렬이 요약 학습을 수행할 트랜스포머에게 자연어 정보를 효과적으로 전달한 것에 기인한 것으로 해석할 수 있다.

Ⅴ. 결 론

최근 자동 문서 요약 분야에서 트랜스포머 기반의 요약 모델이 우수한 성능을 보이고 있지만, 이러한 모델은 별도의 사전학습이나 모델의 구조적 변형 없이 요약을 위한 학습 데이터가 충분히 확보되지 않으면 양질의 요약문을 생성하기 어렵다는 한계를 갖는다. 이러한 한계를 극복하기 위해, 본 연구에서는 한국어 사전학습 언어 모델인 KoBERT의 일부 요소를 추출하여 전통적인 트랜스포머 모델에 적용하는 방안을 제시하였다. 또한, 제안 모델의 성능을 확인하기 위해 Dacon의 요약 데이터에 대한 실험을 수행하였으며, 실험 결과 제안 방법론이 특히 소량의 학습 데이터가 주어진 환경에서 전통적인 기법에 비해 매우 우수한 성능을 나타냄을 확인하였다.

본 논문은 도메인의 특수성으로 인해 텍스트 데이터의 양 자체가 충분하지 않거나 학습 데이터 확보에 많은 비용이 요구되는 환경에서도 양질의 요약문을 생성할 수 있는 방안을 제시했다는 점에서 실무적 기여를 인정받을 수 있다. 또한, 일반적으로 BERT 기반 사전학습 언어 모델을 사용하는 경우 인코더 층 전체를 사용하는 것과 달리, 본 연구에서는 KoBERT 모델의 토큰 임베딩 층만을 발췌하여 사용하였다. 이는 문장 수준이 아닌 단어 수준의 지식 전이를 위한 방안으로, 추후 후속 연구에서 이러한 방안을 활용한 시도가 활발하게 이루어질 것으로 기대한다.

본 연구의 한계 및 추후 연구 방향은 다음과 같다. 우선 트랜스포머 모델은 다양한 하이퍼파라미터(Hyperparameter)를 가지며, 이러한 값들의 구성에 따라 실험 결과가 상이하게 나타날 수 있다. 향후 연구에서는 하이퍼파라미터의 변화에 따른 요약 성능 변화에 대한 엄밀한 평가가 이루어져야 한다. 또한, 추후 연구에서는 학습 데이터의 양뿐만 아니라, 매개변수의 수와 특성이 요약 품질에 미치는 영향에 대한 면밀한 검토가 이루어져야 한다.

참고문헌

1. 김정수・이석준(2015), “주식시장관리제도와 소셜미디어의 역할-개인 투자자 집단 유형과 토픽 분석”, *경영과 정보연구*, 34(5), 23-47.
2. 김현아(2017), 네이버 뉴스에 ‘요약봇’출현..“핵심만 보여줘요, 이데일리.
3. 서명덕(2021), 연합뉴스, 인공지능 기사요약 서비스 첫선, 연합뉴스.
4. 윤성식・전재헌・정상일・정찬식・이석준(2021), “BERT를 활용한 상표 의견제출통지서 거절이유 분류모델 개발”, *경영과 정보연구*, 40(3), 41-58.
5. 장윤희(2016), 카카오, 다음뉴스 전면 개편...뉴스 요약 기능 선보여, 중앙일보.
6. 정해강・김남규(2018), “용어 사전의 특성이 문서 분류 정확도에 미치는 영향 연구”, *경영과 정보연구*, 37(4), 41-62.
7. Allahyari, M. Pouriyeh, S. Assefi, M. Safaei, S.

www.kci.go.kr

Trippe, E. D. Gutierrez, J. B. and Kochut, K.(2017), *Text summarization techniques: a brief survey*, arXiv preprint arXiv:1707.02268.

8. Bahdanau, D. Cho, K. and Bengio, Y.(2014), *Neural machine translation by jointly learning to align and translate*, arXiv preprint arXiv:1409.0473.
9. Cho, K. Van Merriënboer, B. Gulcehre, C. Bahdanau, D. Bougares, F. Schwenk, H. and Bengio, Y.(2014), *Learning phrase representations using RNN encoder-decoder for statistical machine translation*, arXiv preprint arXiv:1406.1078.
10. Deaton, J. Jacobs, A. Kenealy, K. and See, A.(2019), Transformers and pointer-generator networks for abstractive summarization.
11. Devlin, J. Chang, M. W. Lee, K. and Toutanova, K.(2018). *Bert: Pre-training of deep bidirectional transformers for language understanding*, arXiv preprint arXiv:1810.04805.
12. Eduard, H.(2015), *The Oxford Handbook of Computational Linguistics 2nd edition*, Oxford University Press, Oxford.
13. Gambhir, M. and Gupta, V.(2017), "Recent automatic text summarization techniques: a survey", *Artificial Intelligence Review*, 47(1), 1-66.
14. Goodman, S. Lan, Z. and Soricut, R.(2019), *Multi-stage Pretraining for Abstractive Summarization*, arXiv preprint arXiv: 1909.10599.
15. Gu, J. Lu, Z. Li, H. and Li, V. O.(2016), *Incorporating copying mechanism in sequence-to-sequence learning*, arXiv preprint arXiv:1603.06393.
16. Hochreiter, S. and Schmidhuber, J.(1997), "Long short-term memory", *Neural computation*, 9(8), 1735-1780.
17. Khan, A. and Salim, N.(2014), "A review on abstractive summarization methods", *Journal of Theoretical and Applied Information Technology*, 59(1), 64-72.
18. Khandelwal, U. Clark, K. Jurafsky, D. and Kaiser, L.(2019), *Sample efficient text summarization using a single pre-trained transformer*, arXiv preprint arXiv:1905.08836.
19. Liu, Y. and Lapata, M.(2019), *Text summarization with pretrained encoders*, arXiv preprint arXiv:1908.08345.
20. Lin, C. Y.(2004), "Rouge: A package for autom atic evaluation of summaries", *In Text summa rization branches out*, 74-81.
21. Liu, Y. Ott, M. Goyal, N. Du, J. Joshi, M. Chen, D. Lewis, M. Zettlemoyer, L. and Stoyanov, V.(2019), *Roberta: A robustly optimized bert pretraining approach*, arXiv preprint arXiv:1907.11692.
22. Mihalcea, R. and Tarau, P.(2004), "Textrank: Bringing order into text", *In Proceedings of the 2004 conference on empirical methods in natural language processing*, 404-411.
23. Mikolov, T. Sutskever, I. Chen, K. Corrado, G. and Dean, J.(2013), "Distributed represent-ations of words and phrases and their compositionality", *In Advances in neural information processing systems*, 3111-3119.
24. Nallapati, R. Zhou, B. and Ma, M.(2016), *Classify or select: Neural architectures for extractive document summarization*, arXiv preprint arXiv:1611.04244.
25. Nallapati, R. Zhou, B. Gulcehre, C. and Xiang, B.(2016), *Abstractive text summarization using sequence-to-sequence rnns and beyond*,

www.kci.go.kr

arXiv preprint arXiv:1602.06023.

26. Radford, A. Narasimhan, K. Salimans, T. and Sutskever, I.(2018), Improving language understanding by generative pre-training.
27. Radford, A. Wu, J. Child, R. Luan, D. Amodei, D. and Sutskever, I.(2019), "Language models are unsupervised multitask learners", *OpenAI blog*, 1(8), 9.
28. Reid, M., Marrese-Taylor, E., and Matsuo, Y. (2020), Subformer: A Parameter Reduced Transformer.
29. Rothe, S. Narayan, S. and Severyn, A.(2020), "Leveraging pre-trained checkpoints for sequence generation tasks", *Transactions of the Association for Computational Linguistics*, 8, 264-280.
30. Rush, A. M. Chopra, S. and Weston, J.(2015), *A neural attention model for abstractive sentence summarization*, arXiv preprint arXiv:1509.00685.
31. Sanjabi, N.(2018), Abstractive text summarization with attention-based mechanism, Universitat Politècnica de Catalunya, Master's thesis.
32. See, A. Liu, P. J. and Manning, C. D.(2017), *Get to the point: Summarization with pointer-generator networks*, arXiv preprint arXiv:1704.04368.
33. SKT Open Source.(2021), SK telecom Open Source Projects: KoBERT, https://sktelecom.github.io/project/kobert/.
34. Sutskever, I. Vinyals, O. and Le, Q. V.(2014), *Sequence to sequence learning with neural networks*, arXiv preprint arXiv:1409.3215.
35. Vaswani, A. Shazeer, N. Parmar, N. Uszkoreit, J. Jones, L. Gomez, A. N. Kaiser, L. and Polosukhin, I.(2017), *Attention is all you need*, arXiv preprint arXiv:1706.03762.
36. Venkat, N.(2018), *Chapter 12 - Natural Language Core Tasks and Applications*, Handbook of Statistics, 38, 403-428.
37. Xu, S. Li, H. Yuan, P. Wu, Y. He, X. and Zhou, B.(2020), "Self-attention guided copy mechanism for abstractive summarization", *In Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 1355-1362.

www.kci.go.kr

Abstract

Transformer-based Text Summarization Using Pre-trained Language Model†

Song, Euiseok* · Kim, Namgyu**

As a large amount of text data is produced and distributed online with the advent of social media, it has become more difficult for users to extract only necessary information from a vast amount of information. As a result, various attempts have been made to automatically summarize a large amount of text. In particular, the abstractive summarization approach is being actively studied because it can create a new summary with rich contextual expressions. In the abstractive summarization task, neural network-based transformer models show high-performance and are used widely. However, if a sufficient amount of training data is not provided, it is difficult to generate a high-quality summary because the parameters constituting the transformer are not sufficiently learned. In this work, we proposes a text summarization method that generates a high-quality summary given a small amount of training data. Specifically, we extract some elements of KoBERT and apply them to a transformer-based abstractive summarization model. We conducted an experiment on 42,803 cases of Dacon's summary data to evaluate the performance of the proposed methodology. As a result of the experiment, it was confirmed that the proposed methodology showed superior performance based on the ROUGE index compared to the comparative method.

Key Words: Deep Learning, Automatic Text Summarization, Transformer, Pre-trained Language Model

† This study was supported by "High Performance Computing Infrastructure Support Program" of AI Yangjae HUB
* Graduate School of Business IT, Kookmin University, dmltjr802@kookmin.ac.kr
** Professor, Graduate School of Business IT, Kookmin University, ngkim@kookmin.ac.kr

www.kci.go.kr

www.kci.go.kr