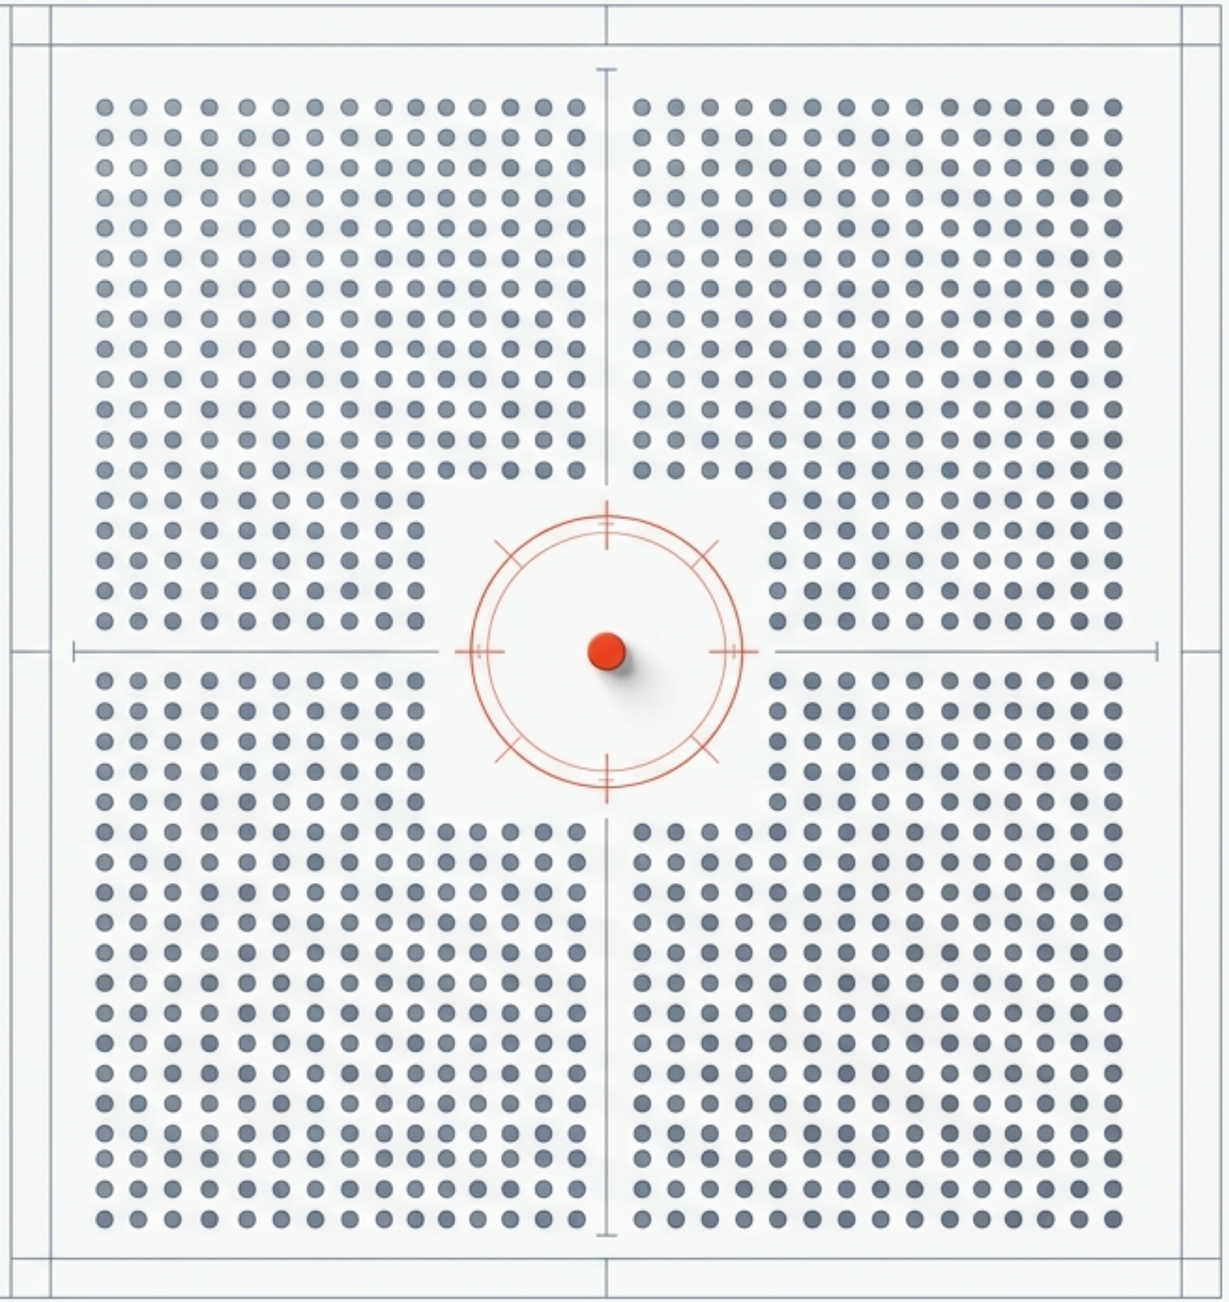
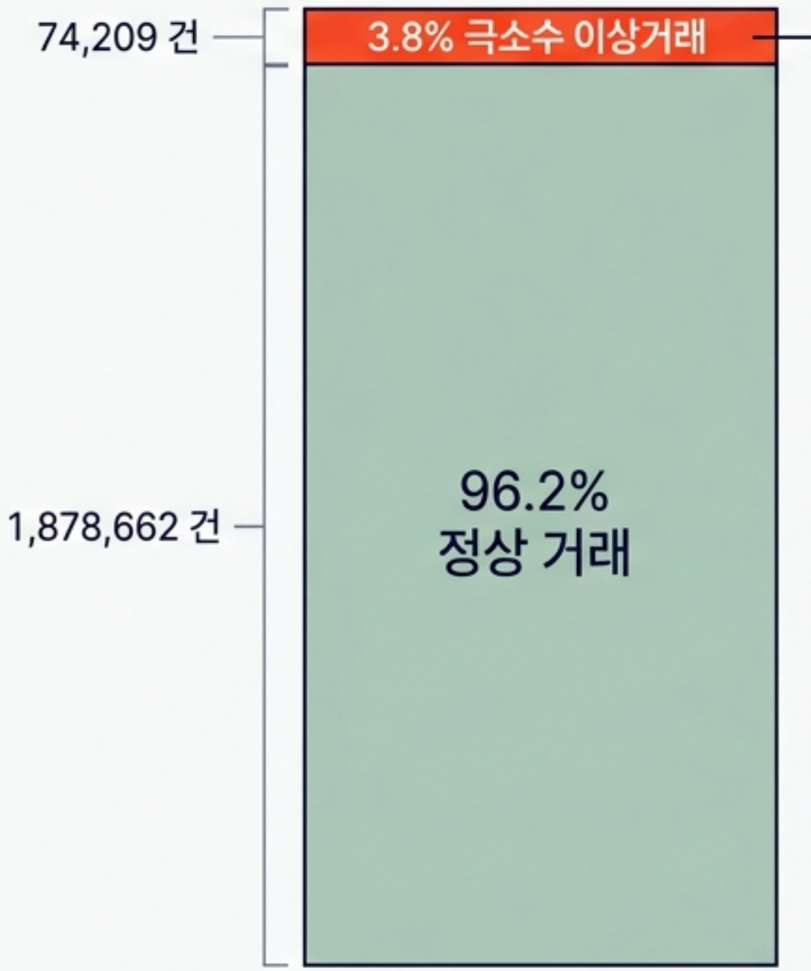
노이즈 속의 시그널: 신용카드 이상거래 탐지 머신러닝 파이프라인

데이터 누수 방지부터 SMOTENC ZMOENC 기반 XGBoost 최적화까지, 탐지율과 오탐율의 완벽한 균형점 찾기



Gemini Notebook

분석을 위협하는 3가지 핵심 과제





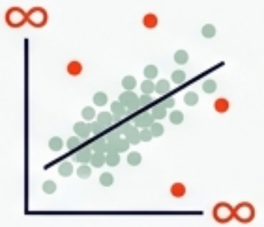
규모와 압도적 불균형

총 195만 건(1,952,871) 이상의 결제 데이터 중 단 3.8%에 불과한 극소수의 이상거래 시그널.



데이터 누수 위험 (Leakage)

사후에만 알 수 있는 정답 정보(이상거래유형 등)가 입력 변수에 혼재되어 모델의 착각을 유발할 위험.

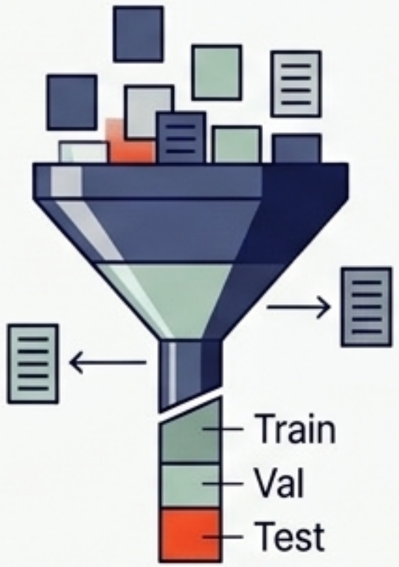


노이즈와 아웃라이어

무한대 값과 극단적 결제 금액 등 금융 데이터 특유의 불안정성.

Gemini Notebook

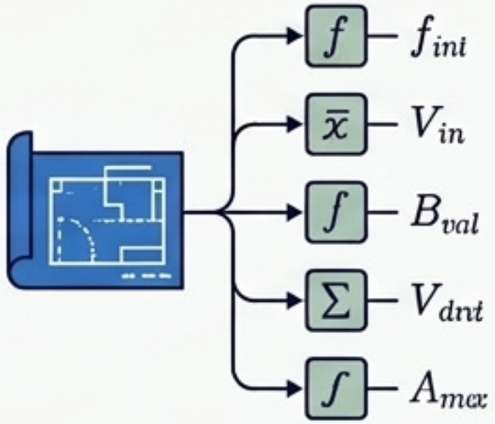
파이프라인 아키텍처: 단계별 리스크 통제망



Target Ratio: 3.8%

Step 1: Split & Filter

타겟 비율(3.8%) 유지
3-Way Split (Train 70% / Val 10% / Test 20%).
데이터 누수 컬럼 제거.



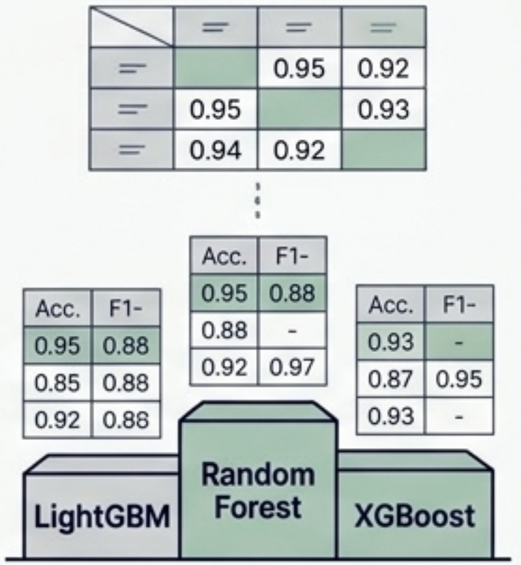
Step 2: Feature Engineering

분석가의 직관을 반영한
6개의 핵심 파생변수 생성.
(Train 기준 평균 결제금액 도출).



Step 3: Scaling & Resampling

이상치에 강건한
RobustScaler 적용 및
SMOTENC를 통한
Train 데이터 불균형 해소.



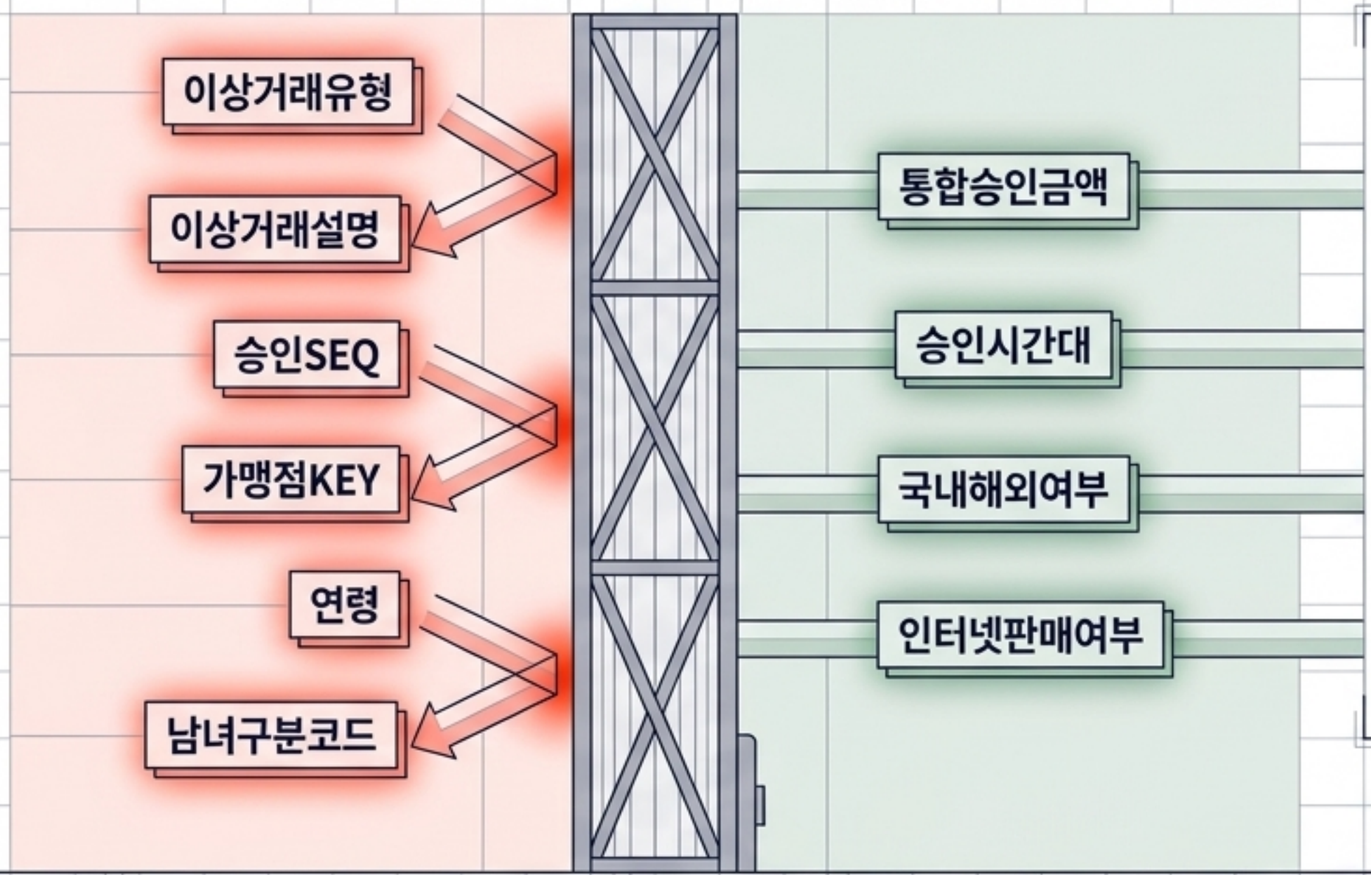
Step 4: Model Showdown

동일한 통제 환경에서
LightGBM, Random Forest, XGBoost 성능 격돌.

Gemini Notebook

데이터 누수 및 편향 방지벽 (The Firewall)

정답 누수 차단,
단순 식별자 암기 방지,
특정 인구통계학적
편향(공정성) 원천 차단.



실시간 탐지 환경에서
즉각적으로 가용 가능한
7개 핵심 원본 피처.

Gemini Notebook

분석가의 직관을 피처로: 파생변수 창출 매트릭스

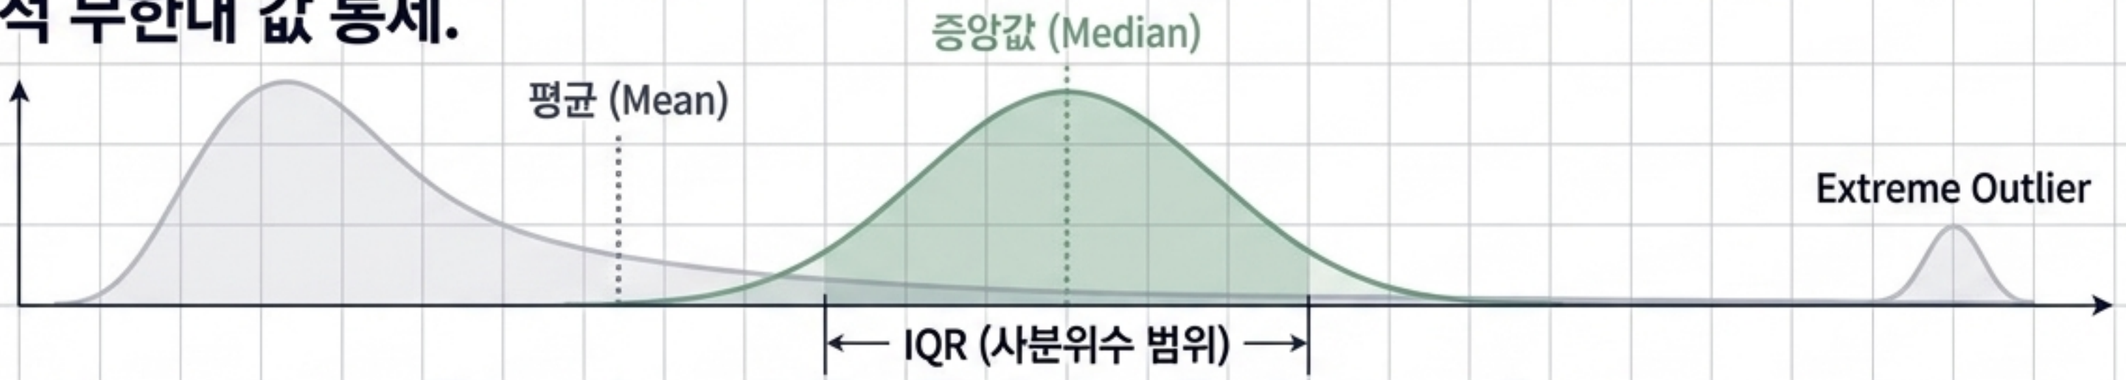
금액 컨텍스트 (Amount)	시간 컨텍스트 (Time)	복합 리스크 (Risk Flags)
amt_to_limit_ratio: 한도 대비 과도한 결제인가? amt_diff_from_user_avg: 평소 씀씀이와 얼마나 다른가? limit_is_zero: 비율 계산 불가 예외 처리	is_midnight: 00~05시 사이의 심야 결제인가? is_weekend: 주말에 발생한 비정형 거래인가?	overseas_online_risk: 해외 결제 + 온라인의 복합 위험인가?

누수 방지 원칙: 고객의 '평소 평균 결제금액'은 오직 Train 데이터에서만 계산하여 Test 데이터로 단방향 매핑함.

Gemini Notebook

강건한 스케일링 체계: RobustScaler & 누수 통제

아웃라이어 제어: 평균(Mean) 대신 중앙값(Median)과 사분위수(IQR)를 사용하여 극단적 무한대 값 통제.

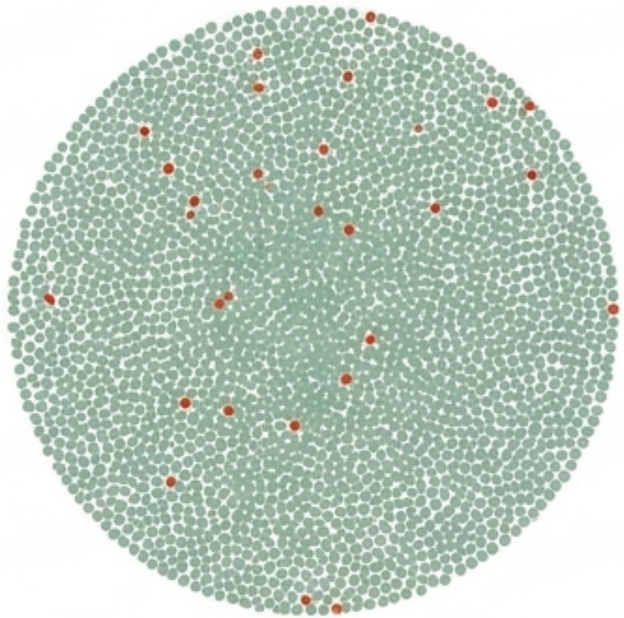


단방향 격리 (Isolation): 오직 Train 데이터에서만 스케일링 기준을 학습하여 미래 데이터의 사전 유입 완벽 차단.



Gemini Notebook

희미한 시그널의 증폭: SMOTENC 오버샘플링

적용 전 (Before)	적용 후 (After)
	
적용 전: 50,405건 (정상의 약 3.8%)	적용 후: 263,320건 (정상거래의 20% 수준까지 증폭)

숫자형과 범주형(0, 1)이 혼재된 카드 데이터의 특성을 고려하여 SMOTENC 채택.
Test 셋(39만 건)은 철저히 원본 비율을 유지하여 현실 세계의 성능을 검증.

Gemini Notebook

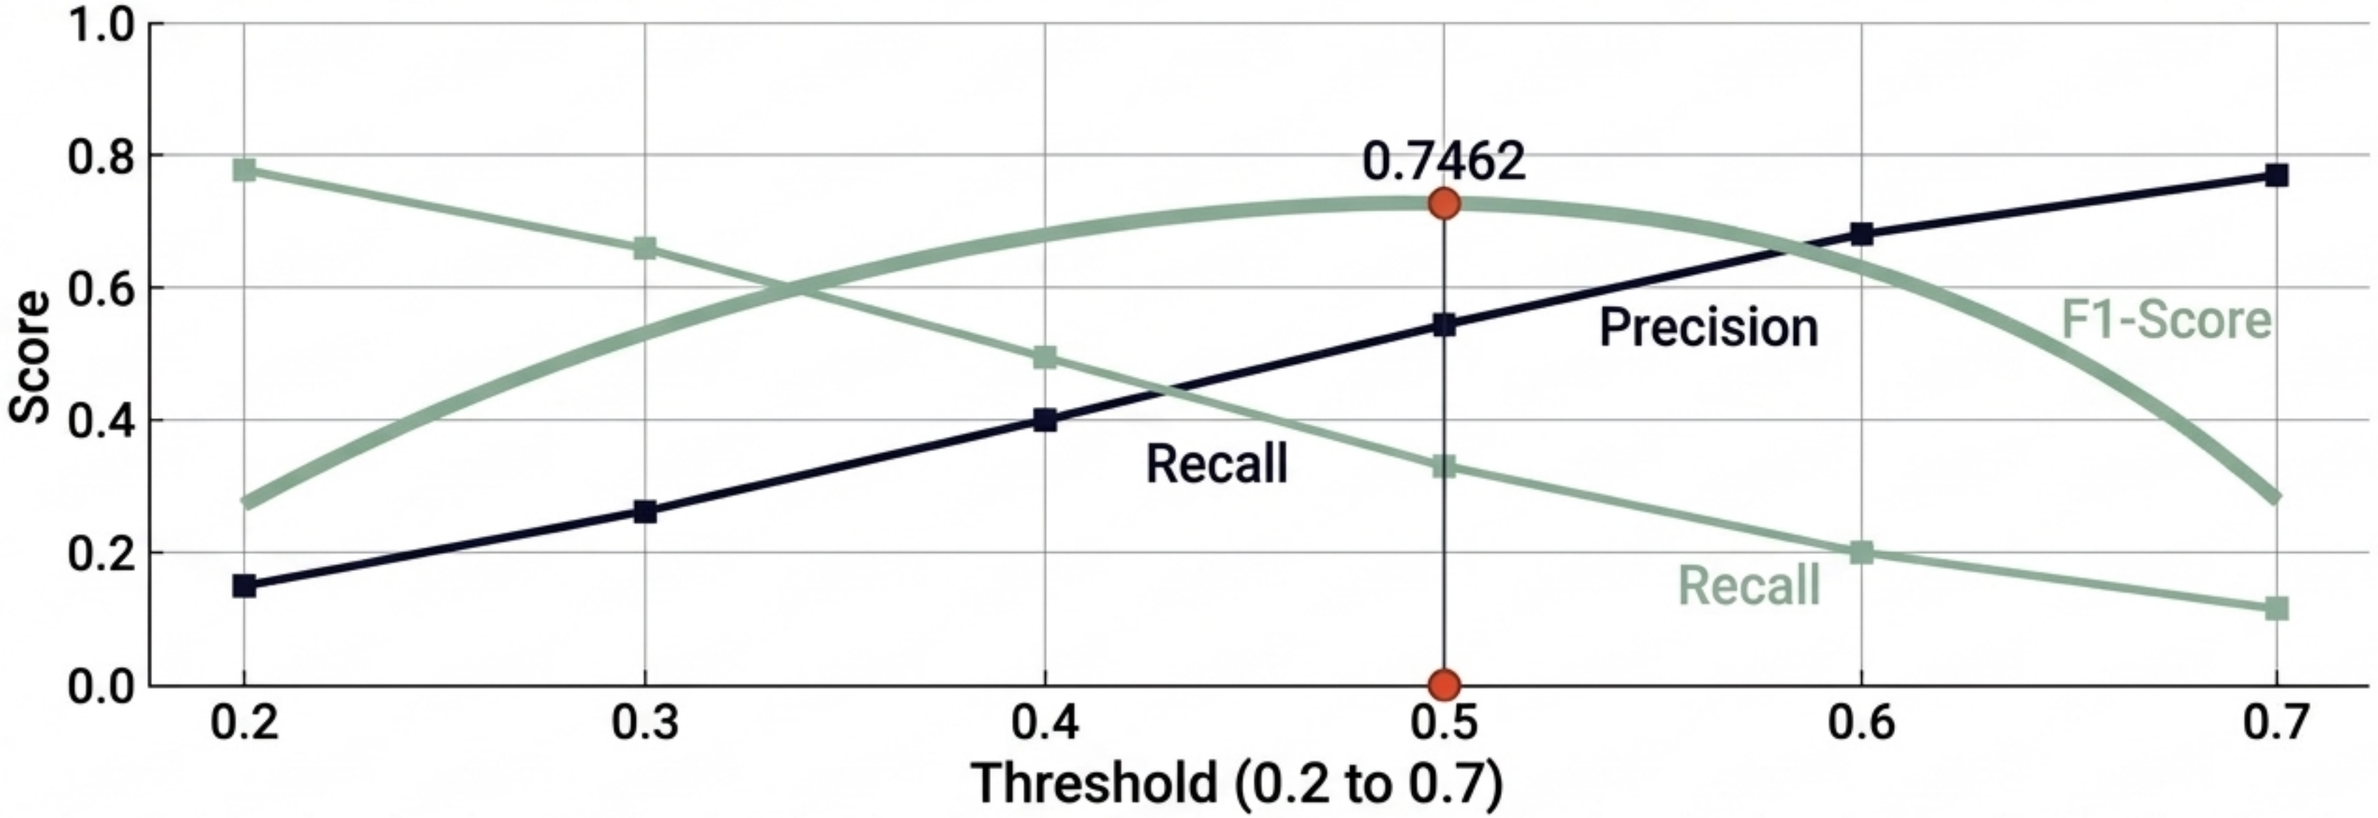
모델의 진화: 오버샘플링 트레이드오프 검증

미적용 (Baseline)		SMOTENC 적용
F1-Score: 0.7187		F1-Score: 0.7210
Recall: 0.6366	Recall 상승 (미탐 감소)	Recall: 0.6511
Precision: 0.8251	Precision 하락 (오탐 증가)	Precision: 0.8077
PR-AUC: 0.7635		PR-AUC: 0.7650

오탐(False Alarm)을 약간 감수하더라도 미탐(Missing Fraud)을 유의미하게 줄이는 방향으로 F1-Score와 PR-AUC 상승. 데이터 증강 전략의 타당성 입증.

Gemini Notebook

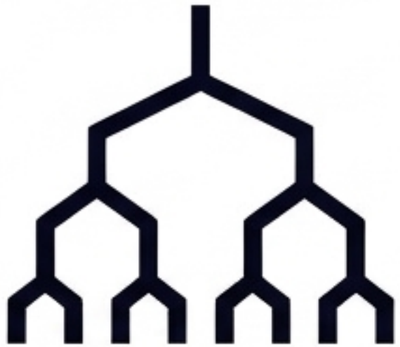
최적의 균형점 탐색: Threshold Tuning



임계값 하향 (예: 0.2) - 적발 위주. 미탐은 줄지만, 정상고객 카드 정지로 인한 CS 민원 폭발 (오탐 급증).	임계값 0.5 - Validation F1-Score 최상단 (0.7462). Precision과 Recall의 가장 견고한 타협점.	임계값 상향 (예: 0.7) – 정확도 위주. 오탐은 줄지만, 실제 사기 피해를 하는 비즈니스 리스크 극대화 (미탐 급증).

Gemini Notebook

삼자대면: 최적의 알고리즘을 위한 라인업

Random Forest	LightGBM	XGBoost
		
앙상블의 전통적 강자. 깊고 넓은 트리(max_depth=12)로 안정성 추구.	속도와 효율성의 정점. 리프 중심 트리 분할(num_leaves=31)로 빠른 비대칭 패턴 학습.	압도적 견고함. 엄격한 정규화와 히스토그램 기반 분할로 과적합 방지.

공정한 검증 환경: 세 모델 모두 동일한 SMOTENC Train 데이터 학습,
동일한 Test 셋 평가, 임계값 0.5 적용.

Gemini Notebook

종합 모델 평가 매트릭스 (Test Data 기준)

Model	Precision	Recall	F1-Score	PR-AUC
Random Forest	0.7261	0.6945 (최고)	0.7100	0.7548
LightGBM	0.8077	0.6511	0.7210	0.7650 (최고)
XGBoost	0.8209 (최고)	0.6488	0.7248 (최고)	0.7644

RF는 많이 잡지만(Recall 최고)
헛스윙(Precision 최하)이 너무 잦아
비즈니스 적용 탈락.

최상위 안정성과 정확도를 뽐낸
XGBoost가 F1-Score 및 Precision
1위로 최종 우승.

Gemini Notebook

승자 분석: 왜 XGBoost가 최종 선택인가?

완벽한 밸런스 (F1 0.7248)

극단적인 불균형 데이터 속에서도 미탐과 오탐 사이의 가장 높은 조화율 달성.

압도적 비용 효율성 (Precision 0.8209)

탐지된 알람의 82% 이상이 실제 사기. '정상 고객의 카드를 잘못 정지" 하여 발생하는 CS 민원 대응 비용 및 브랜드 신뢰도 하락 최소화.

XGBoost

일관된 일반화 (Generalization)

Validation과 Test 간의 성능 낙폭이 매우 좁아,
처음 보는 미래의 거래 데이터에서도 강건하게 작동할 것임을 증명.

Gemini Notebook

전략적 대안: 비즈니스 목표에 따른 LightGBM의 활용

적발 극대화 중심 (Plan B: LightGBM)

Recall(0.6511)과 PR-AUC(0.7650)가 미세하게 더 높아 사기 적발률 자체를 끌어올려야 할 때의 훌륭한 우회로.

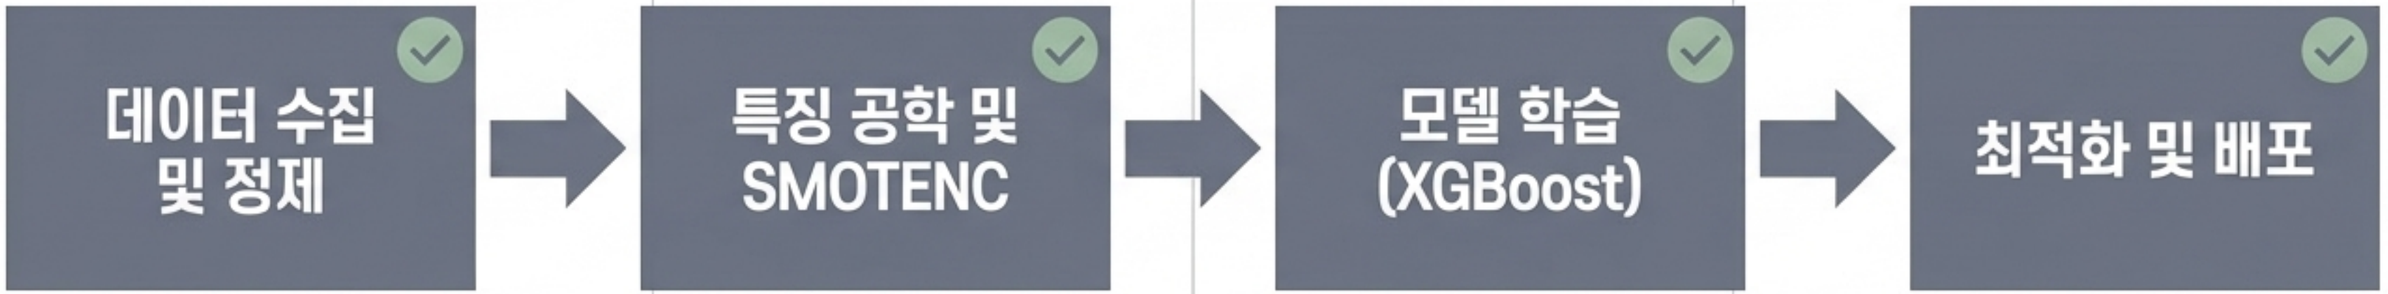
오탐 방지 중심 (현재 전략: XGBoost)

고객 경험 보호를 최우선으로 할 때의 최적 선택.

만약 회사의 리스크 관리 정책이 '단 한 건의 이상거래도 놓치지 마라(미탐 최소화)'로 변경된다면?
모델 간 성능 차이가 크지 않아 언제든 비즈니스 KPI 변화에 맞춰 유연한 모델 스위칭이 가능함.

Gemini Notebook

결론 및 Next Steps (The Blueprint Executed)



Summary (The Execution)

1. 철저한 방화벽 설계로 데이터 누수 원천 차단.
2. SMOTENC 기반의 전략적 데이터 증폭으로 클래스 불균형 완벽 해소.
3. XGBoost 최적화를 통해 오탐을 최소화한 실용적 이상거래 탐지 엔진 구축 완료.

Next Steps

1. 제외되었던 가맹점 세부 코드 및 고객 세그먼트 변수의 신중한 도입 실험 (편향성 모니터링 병행).
2. 배치(Batch) 형태를 넘어 실시간 스트리밍(Streaming) 데이터 환경으로의 모델 배포 아키텍처 준비.

Gemini Notebook