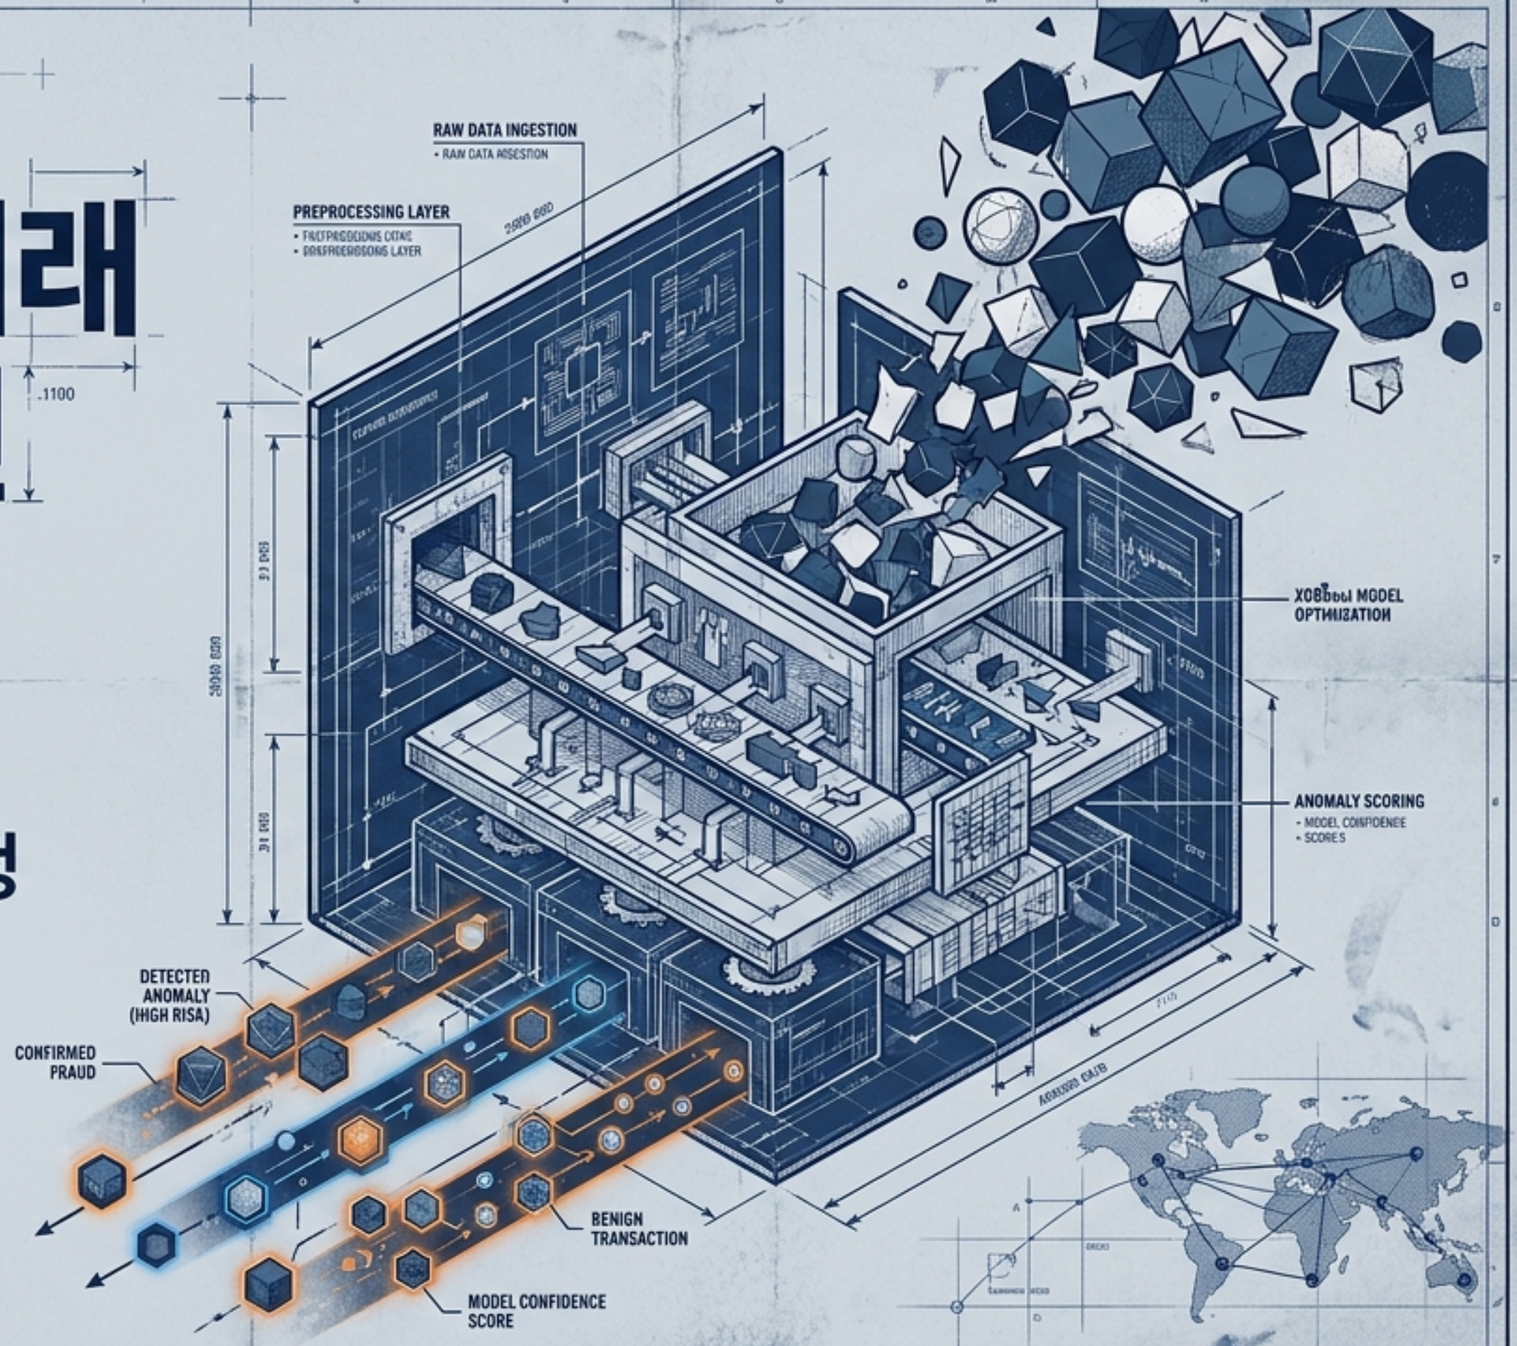
신용카드 이상거래 탐지 파이프라인 설계 청사진

원시 데이터 전처리부터 XGBoost 모델 최적화까지의 여정



CLASSIFIED

CLASSIFIED DOCUMENT - FORENSIC DATA ARCHITECTURE

PROJECT: CREDIT CARD ANOMALY DETECTION

Gemini Notebook

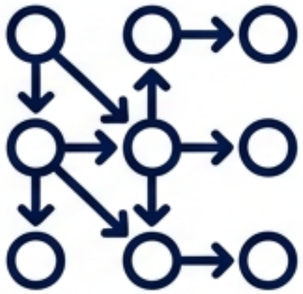
데이터 정제 및 모델 최적화 핵심 요약



1,952,871

건의 전체 훈련 및 검증 거래 데이터 통합

DATA VOLUME



13

도메인 지식이 반영된 엄선된 핵심 피처
(원본 7개 + 파생 6개)

ENGINEERED FEATURES



3.8%

극심한 클래스 불균형
(SMOTENC 기법을 통해 극복)

THE CHALLENGE



XGBoost

최우수 모델 선정
(최종 Test F1-Score 0.7248, PR-AUC 0.7644)

WINNING ALGORITHM

Gemini Notebook

클래스 비율을 보존하는 데이터 통합 및 분할 흐름



Gemini Notebook

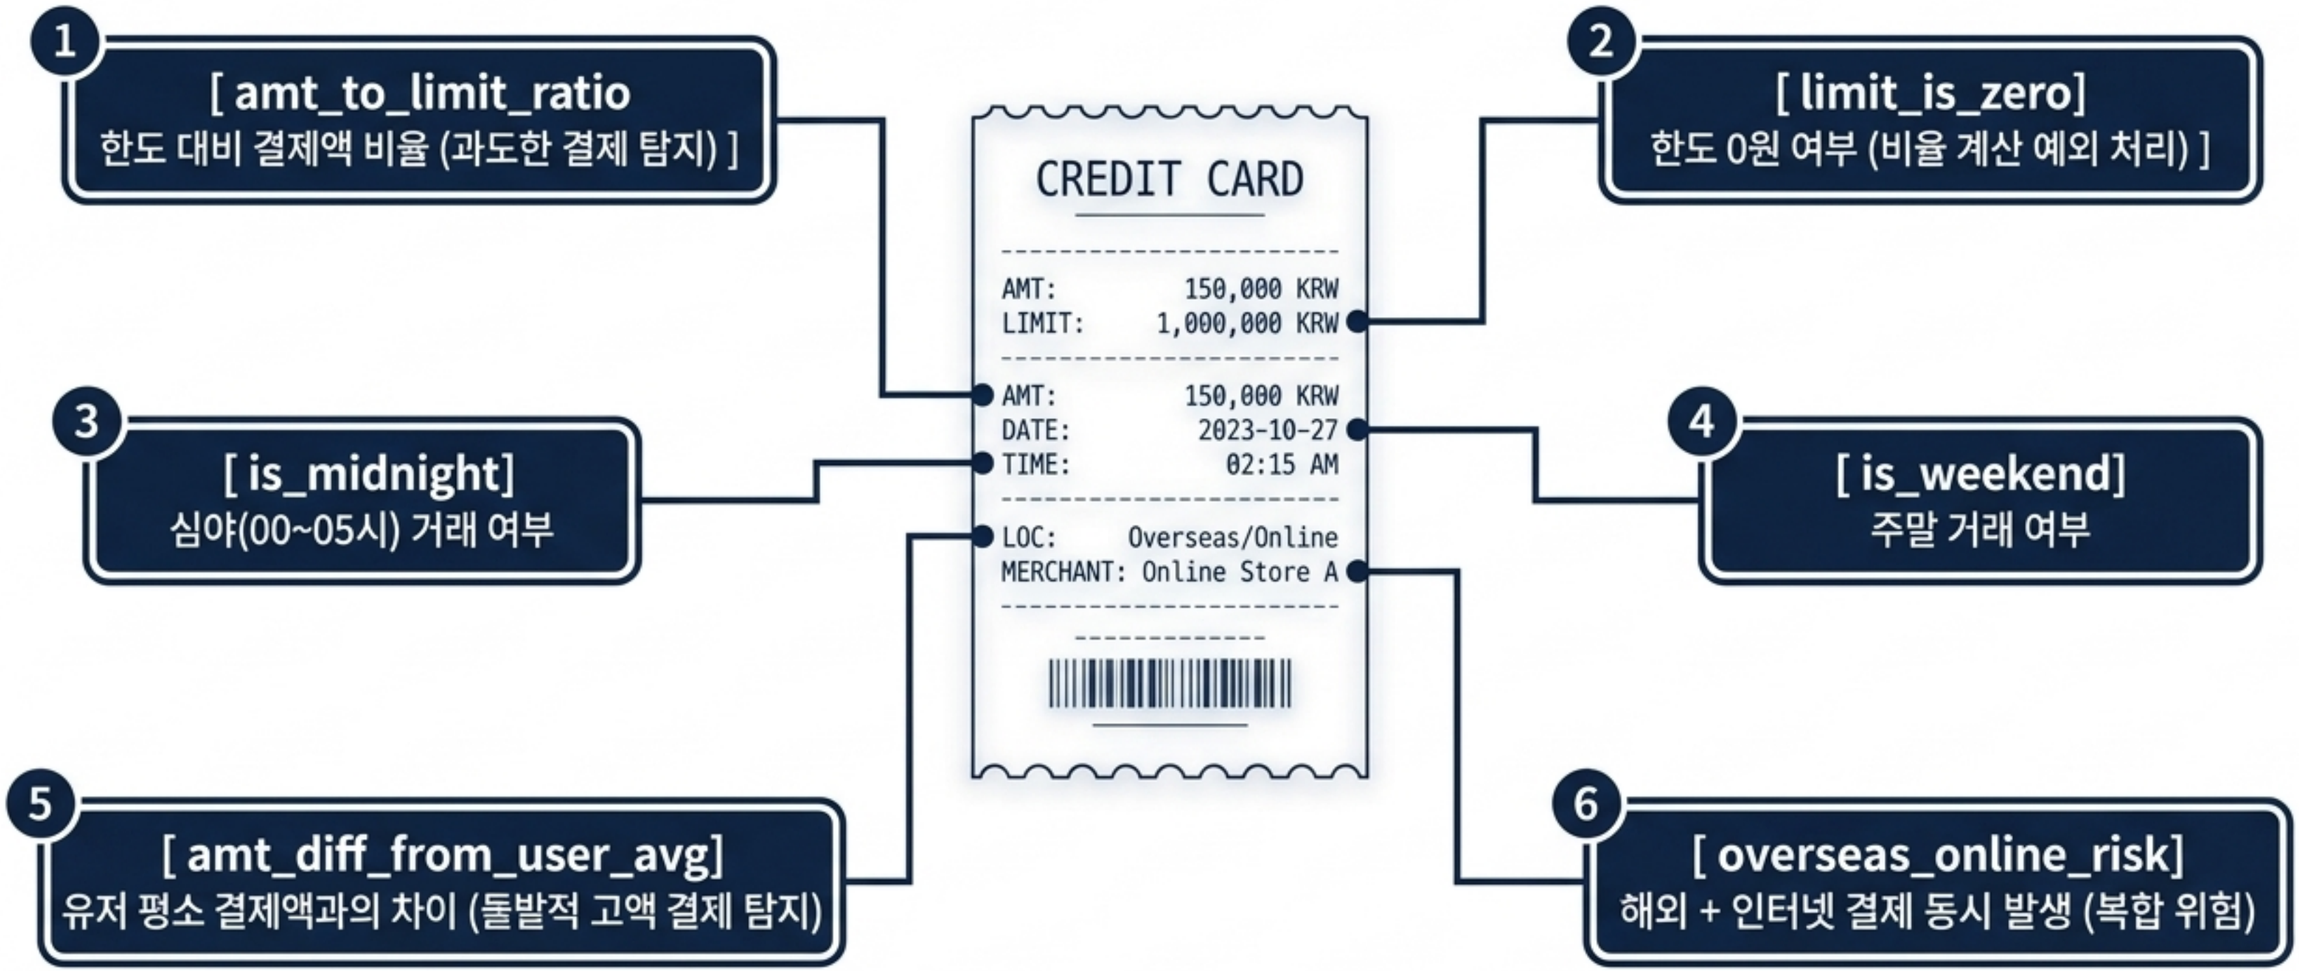
정확한 패턴 학습을 위한 변수 선택 및 배제 기준

유지된 7대 원본 변수
✓ 통합승인금액
✓ 카드이용한도금액
✓ 승인시간대
✓ 국내해외여부
✓ 가맹점여부_신규
✓ 인터넷판매여부
✓ 경과일수_최종이용일자

배제된 변수 및 사유
⚠ 정답 누수 Leakage
이상거래유형, 이상거래설명 (사후 정보로 인한 누수 위험)
편향 방지 Bias
남녀구분코드, 연령 (특정 집단 과탐지 및 공정성 훼손 방지)
✂ 과적합 방지 Overfitting
승인SEQ, 가맹점KEY (고유 식별자 및 세부 코드에 대한 과적합 방어)

Gemini Notebook

도메인 지식을 주입한 핵심 파생 변수 생성



Gemini Notebook

테스트 데이터 누수를 차단하는 파이프라인 절대 원칙

대원칙: Test 데이터는 철저히 미래의 데이터로 취급한다



- 중앙값 대체: 결측치 대체를 위한 중앙값은 오직 Train 데이터에서만 추출하여 적용.
- 유저 평소 소비액: 현재 거래를 제외한 평균을 Train에서 계산 후 Test에 맵핑.
- 스케일링 기준: RobustScaler의 사분위수는 Train으로만 학습하여 Test에 적용.
- 클래스 증강: SMOTENC 오버샘플링은 Train 데이터에만 국한하여 원본 분포 유지.

Gemini Notebook

결측치 독립 범주화 및 이상치 방어 스케일링

Step 1: 연속형 결측치 및 무한대 처리

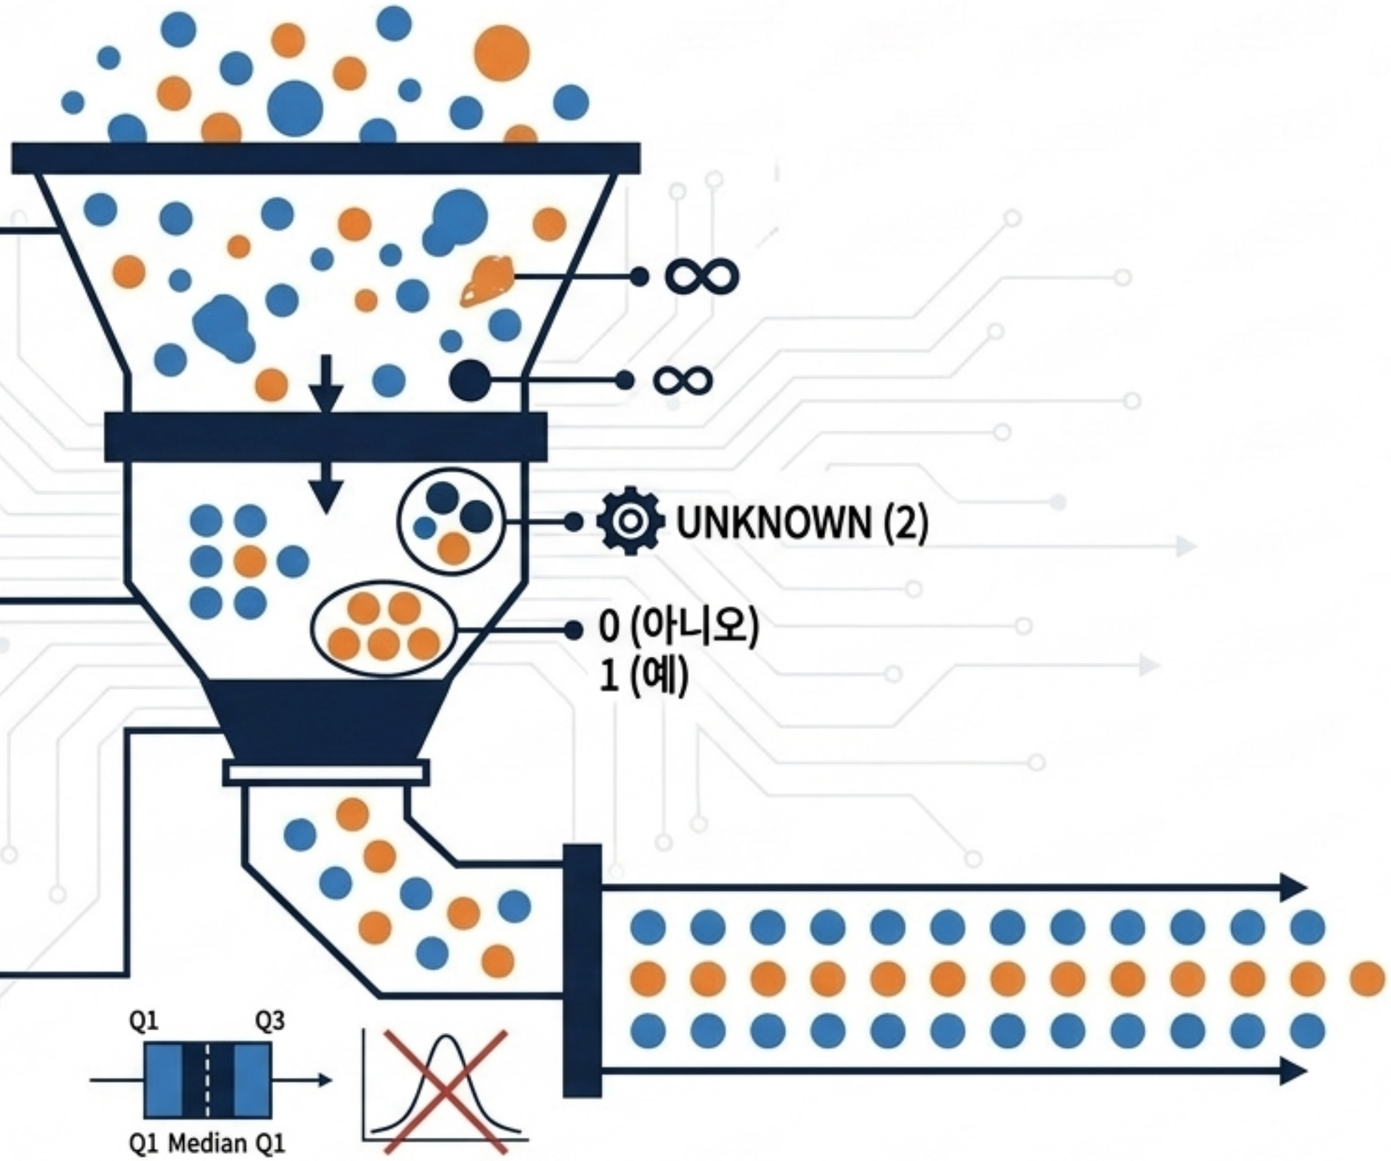
무한대 값 제거 후
Train 중앙값(Median)으로 일괄 대체.

Step 2: 범주형 결측치 범주화

0(아니오), 1(예)과 겹치지 않도록 숫자 '2'를 할당하여 'UNKNOWN'이라는 독립 범주로 모델에 인식시킴.

Step 3: RobustScaler 적용

결제 금액 등 극단적인 이상치(Outlier)가 많은 금융 데이터 특성을 고려하여 평균/표준편차 대신 중앙값/사분위수 기반의 Robust 스케일링 채택.

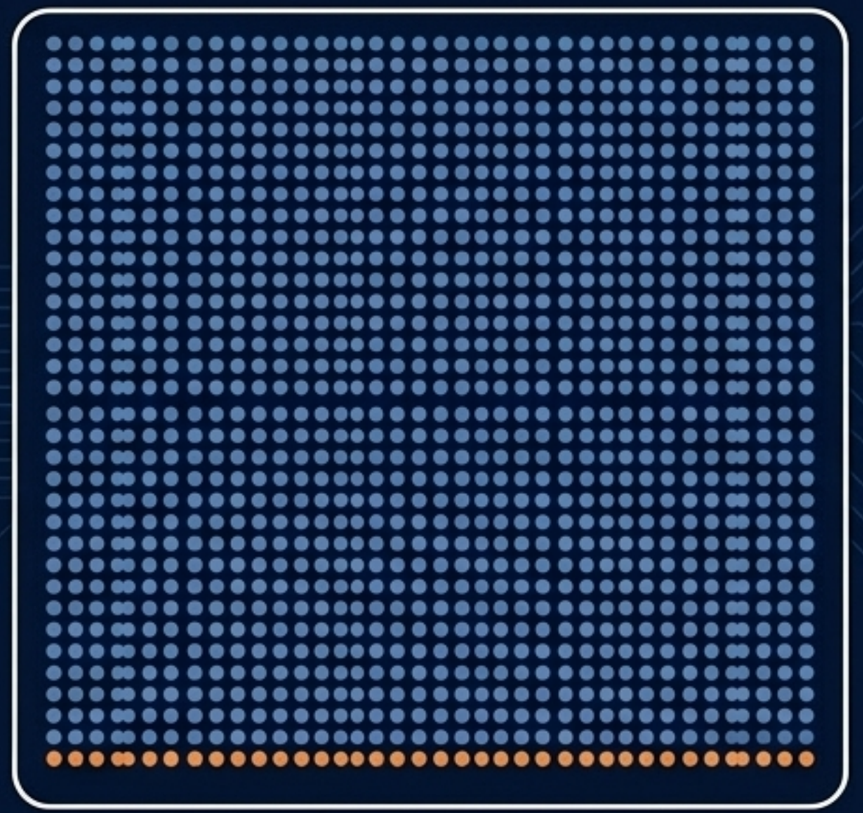


Gemini Notebook

SMOTENC를 활용한 극심한 클래스 불균형 극복

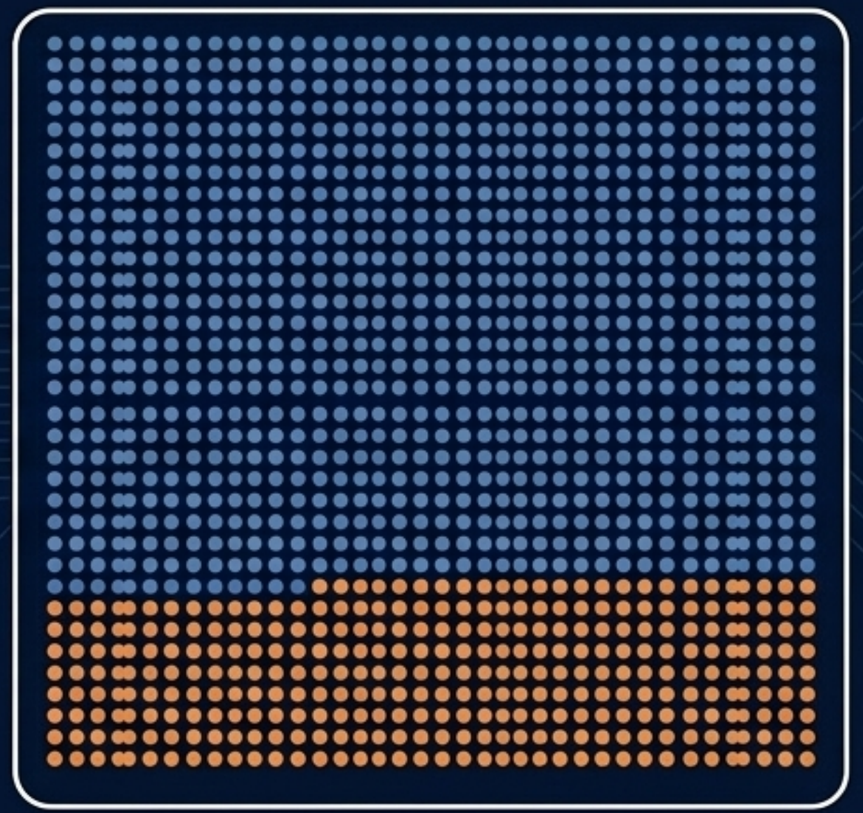
목적: 범주형 변수를 훼손하지 않으면서 소수 클래스(이상거래)를 합성하여 모델의 탐지력 극대화

적용 전 - Before



정상거래 1,316,604건 / 이상거래 50,405건

적용 후 - After



정상거래 1,316,604건 / 이상거래 263,320건

Gemini Notebook

데이터 증강 기법의 실효성 검증

목표: 오탐을 일부 감수하더라도 이상거래 탐지율(Recall) 향상 달성

SMOTENC 미적용 (LightGBM)



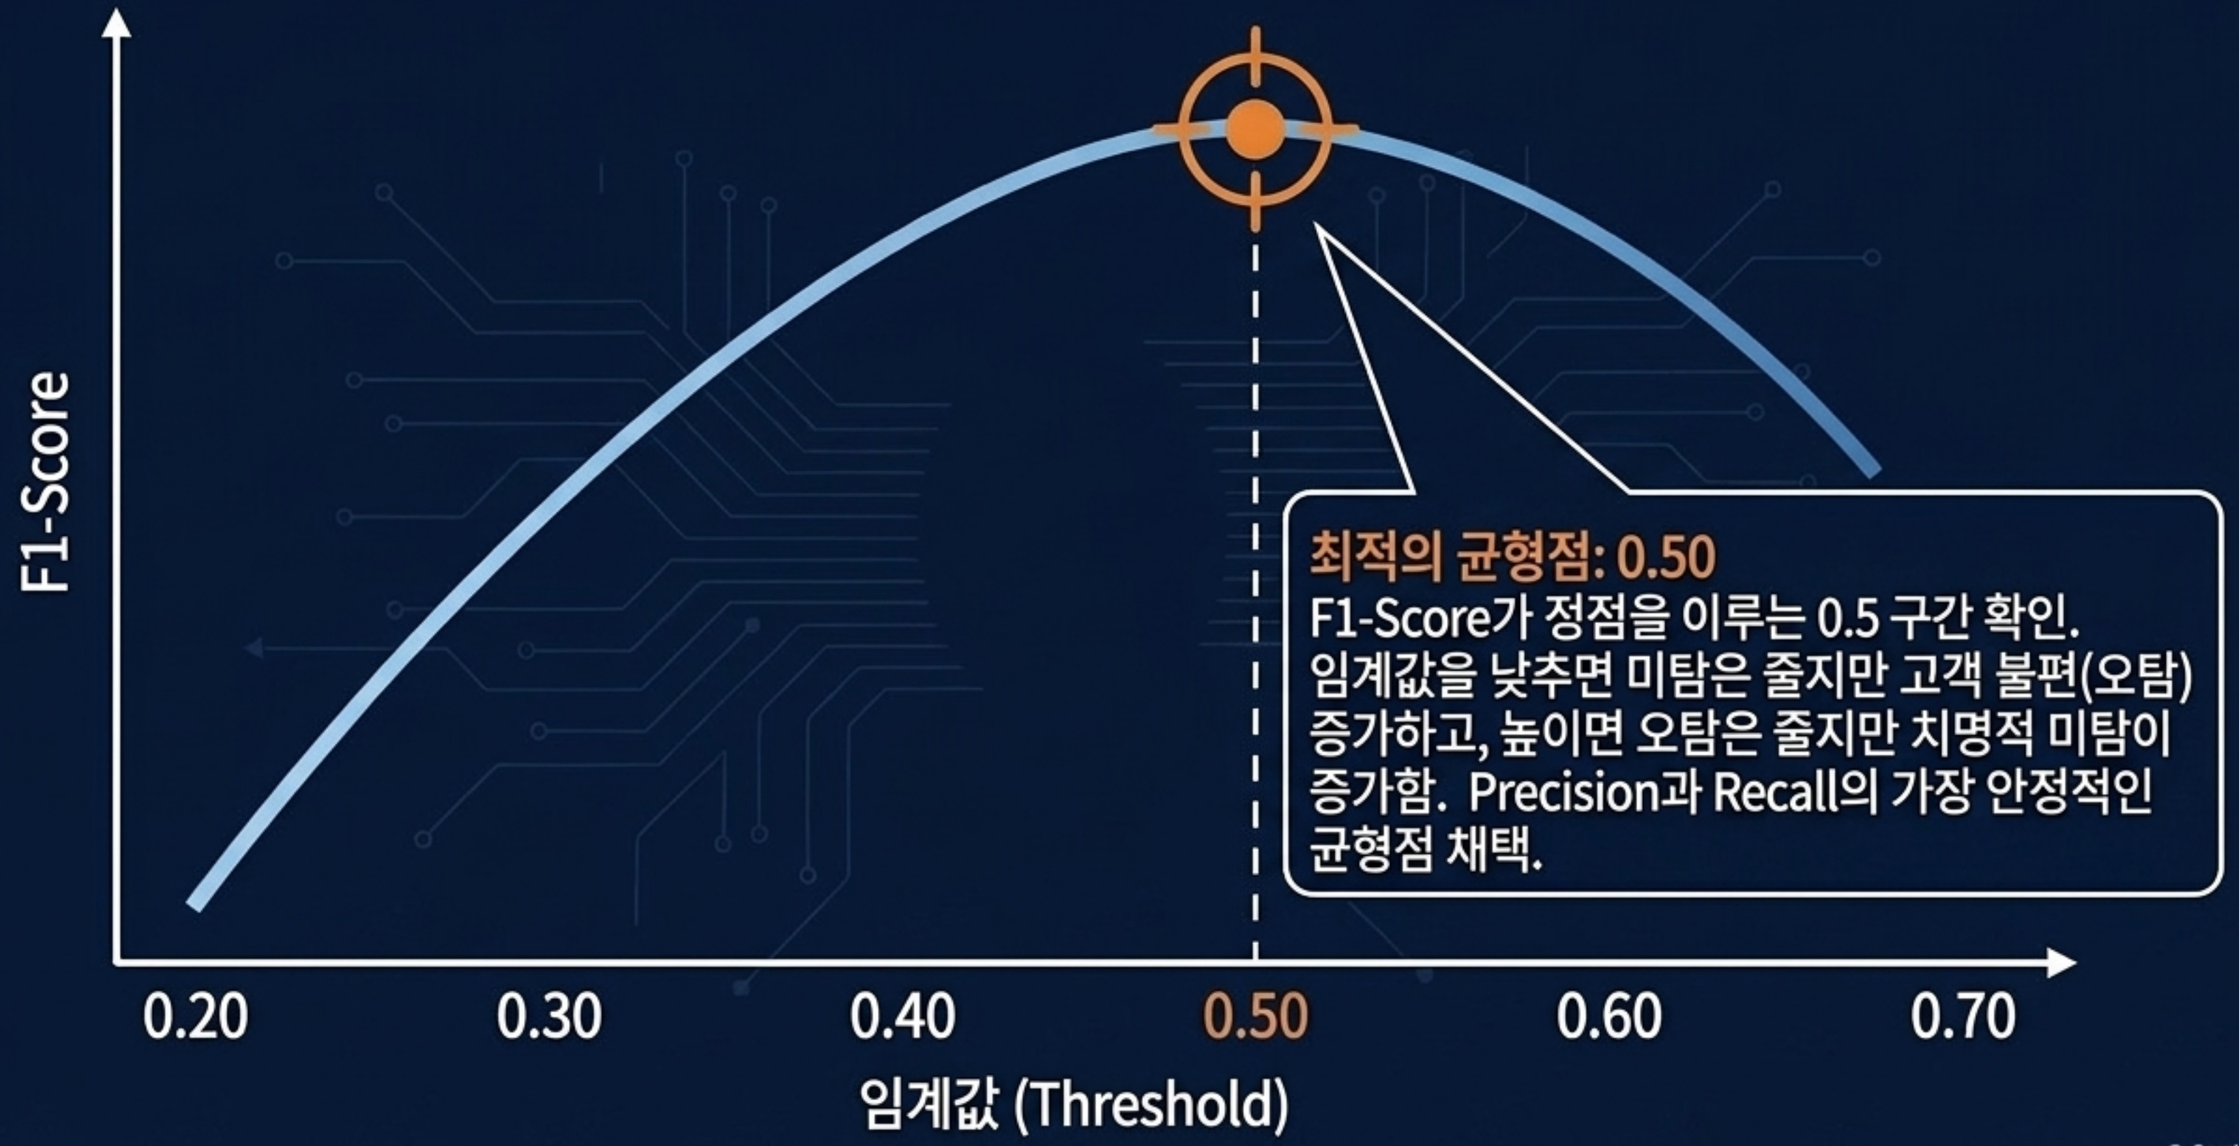
SMOTENC 적용 (LightGBM)



결론: 약간의 오탐(Precision 하락)을 감수하더라도 금융 범죄를 놓치지 않는 것(Recall 향상)이 비즈니스 도메인상 더 중요하므로 증강 기법 적용이 타당함.

Gemini Notebook

오탐과 미탐을 조율하는 최적 임계값 탐색



Gemini Notebook

동일 조건 하의 3대 앙상블 알고리즘 격돌

공통 조건 : SMOTENC 적용 Train 데이터 학습, 임계값 0.5, Random State 42



LightGBM

- n_estimators: 300
- max_depth: 6
- learning_rate: 0.05

빠르고 가벼운 연산,
뛰어난 PR-AUC 확보



Random Forest

- n_estimators: 300
- max_depth: 12
- min_samples_leaf: 2

가장 높은 Recall 기반의
안정적인 병렬 앙상블



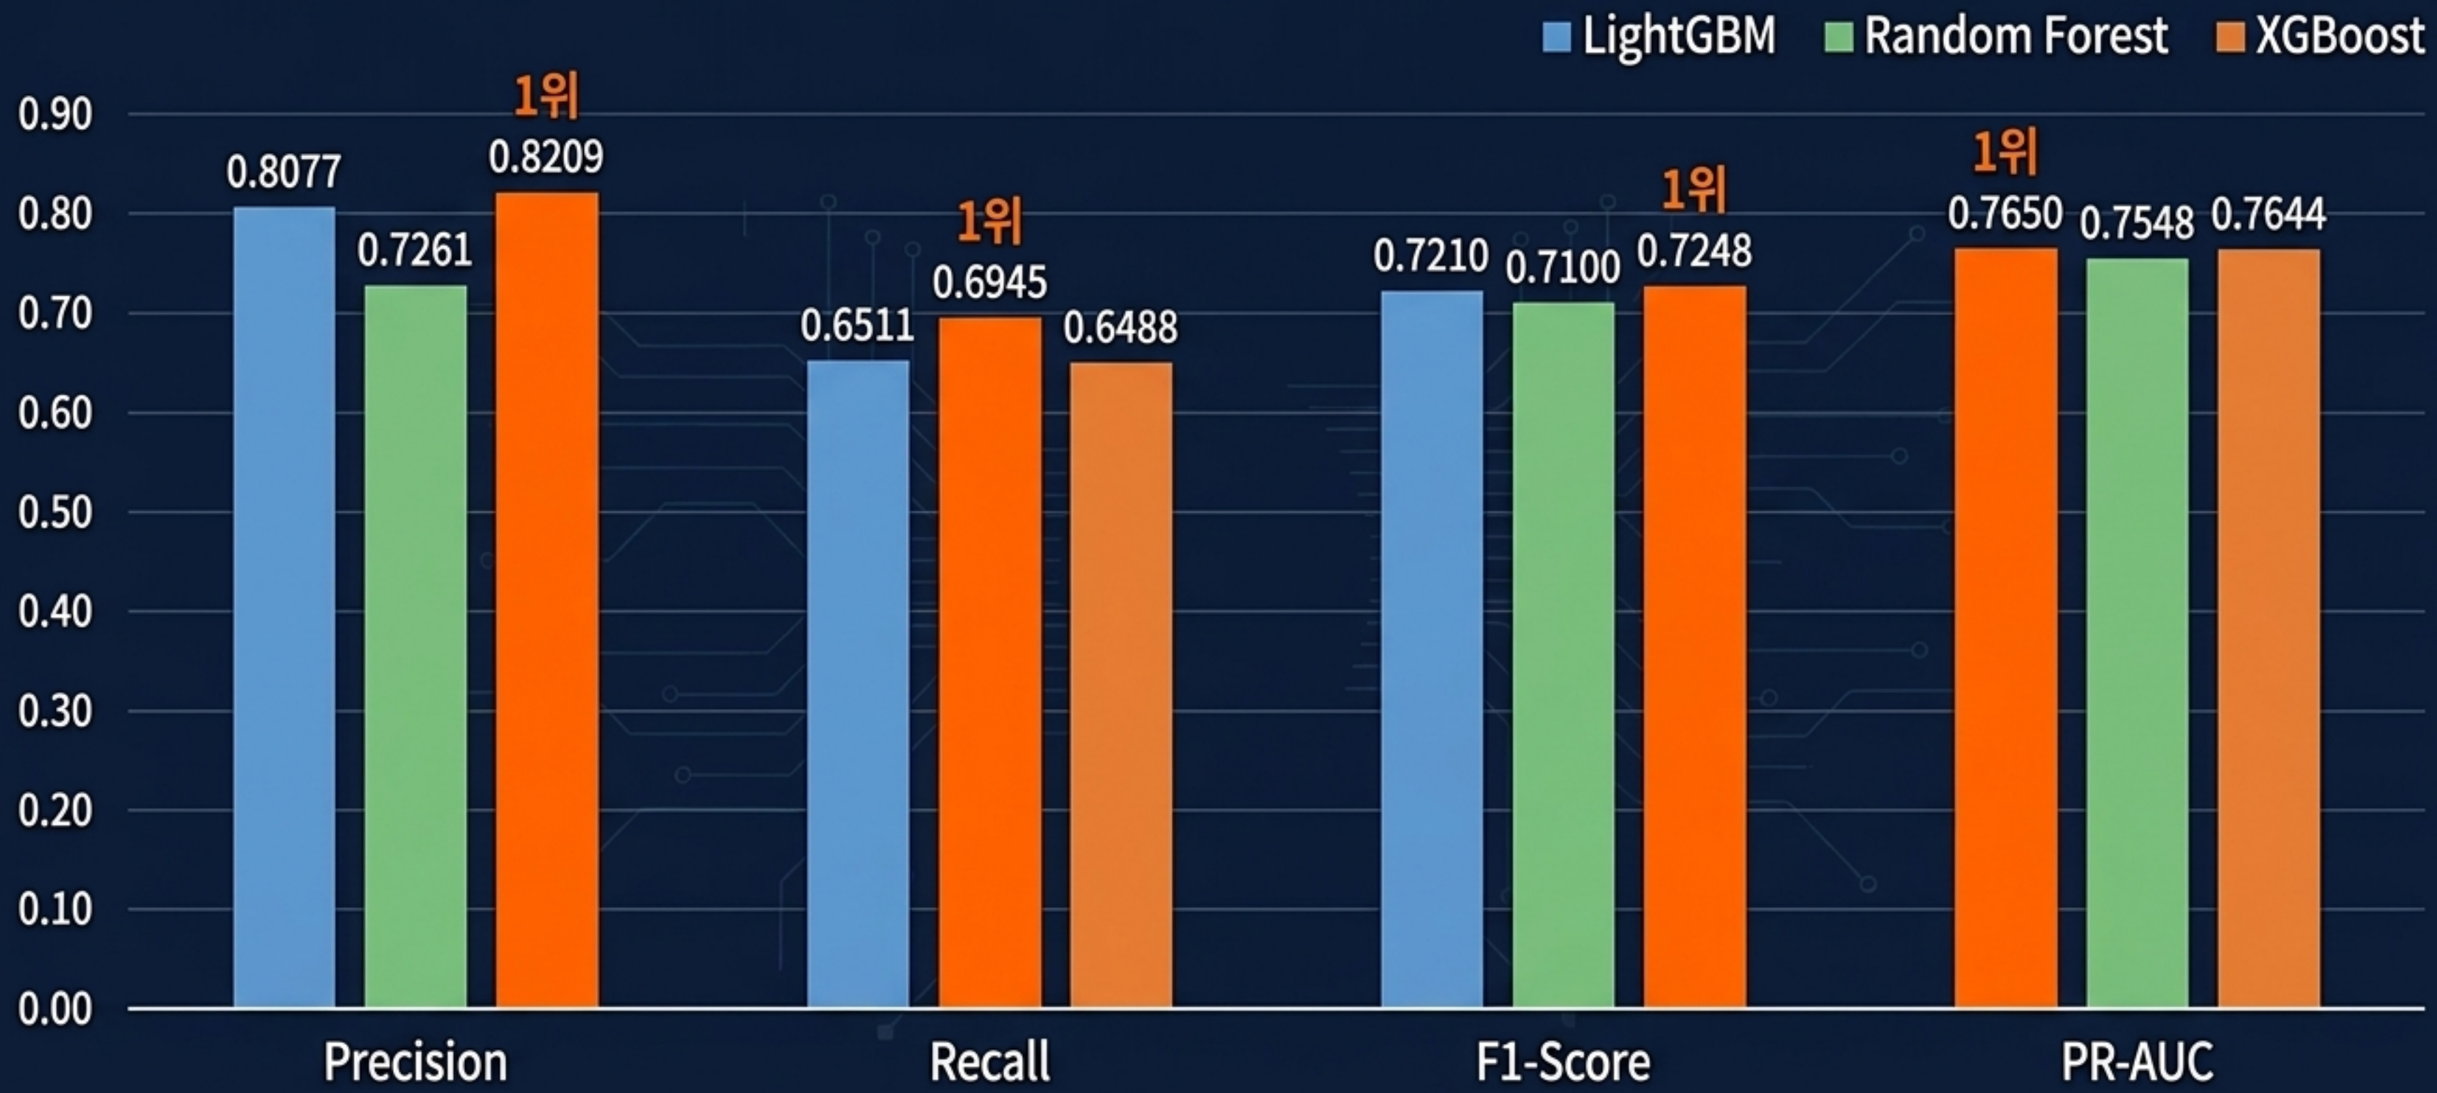
XGBoost

- n_estimators: 300
- max_depth: 6
- learning_rate: 0.05

정교한 오차 보정을 통한
압도적인 정밀도 강점

Gemini Notebook

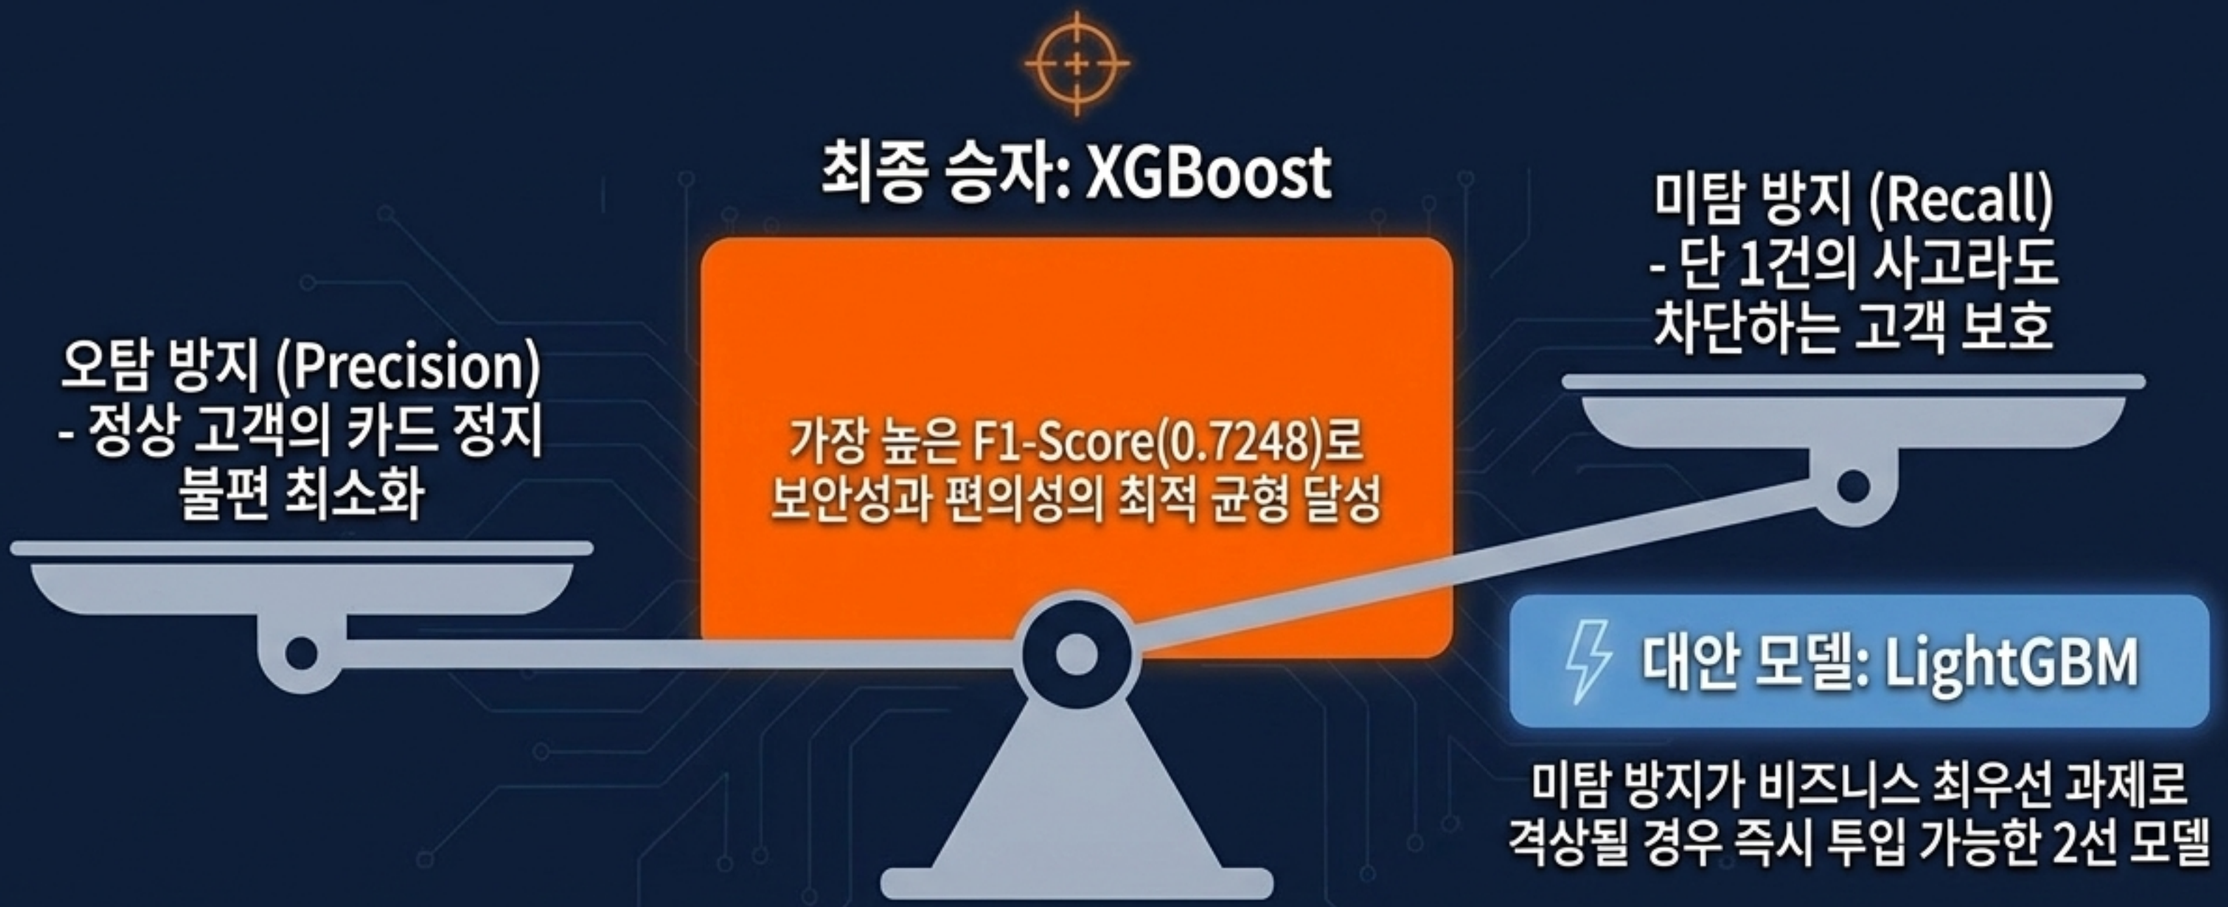
최종 테스트 데이터 기반 알고리즘 성과 분석



* Accuracy는 모든 모델이 98% 이상을 기록했으나, 극심한 불균형 데이터 특성상 주 평가 지표에서 배제함.

Gemini Notebook

최종 모델 선정 및 비즈니스 시사점



Key Takeaway: 단순한 알고리즘 튜닝을 넘어, 13개의 도메인 융합 파생 변수와
철저한 누수 방지 아키텍처가 결합되어 완성된 견고한 이상거래 탐지 시스템 확보.

Gemini Notebook