카드 거래 이상탐지(FDS) 데이터 전처리 및 머신러닝 모델 구축 브리핑 문서

1. 경영진 요약 (Executive Summary)

본 보고서는 카드 거래 데이터를 활용하여 이상거래(Fraud)를 탐지하기 위한 머신러닝 파이프라인의 구축 과정, 데이터 누수 방지 전략, 데이터 전처리 및 모델별 성능 평가 결과를 집계·분석한 브리핑 문서입니다.

- **데이터 통합 및 구조** : 2021년부터 2024년까지의 분기별 카드 거래 데이터 총 1,952,871건(Train 1,735,885건 + Validation 216,986건)을 수집하여 하나로 결합한 후, 정답 클래스(이상거래여부, 약 3.8%) 비율을 유지하는 층화 추출(Stratified Split)을 적용하여 **Training 70% (1,367,009건), Validation 10% (195,287건), Test 20% (390,575건)**의 독립 데이터셋으로 분할하였습니다.
- **데이터 누수(Data Leakage) 엄격 통제** : 정답을 직접적으로 암시하는 변수(이상거래유형, 이상거래설명) 및 식별자/개인정보성 변수를 차단하였습니다. 또한, 카드별 평균 결제금액 계산 시 Train 데이터에서 자기 자신 거래를 제외하고 산출하였으며, 결측치 중앙값 대체, RobustScaler 변환, SMOTENC 데이터 증강 등 모든 전처리 기준을 Train 데이터로만 학습·선정하여 Test 데이터로의 정보 유출을 완벽히 차단하였습니다.
- **피처 엔지니어링** : 실제 거래 시점에서 확보 가능한 원본 변수 7개와 과도한 결제, 심야/주말 패턴, 평소 결제 패턴 대비 변동성, 해외 온라인 복합 위험도 등을 반영한 파생변수 6개를 포함하여 **총 13개 입력 피처** 를 구획하였습니다.
- **주요 성능 평가 결과** :
- **LightGBM 모델** : SMOTENC 적용 시 이상거래 재현율(Recall)이 상승하며 미탐지 위험을 완화시켰습니다. Test 데이터셋 기준 **PR-AUC 0.7650(코드 실행 결과 0.7426), F1-score 0.7210~0.7224** 의 우수한 성과를 기록하였습니다.
- **Random Forest 모델** : SMOTENC 적용 시 이상거래 Recall은 약 69 ~~70% 수준으로 LightGBM 대비 높았으나, 정밀도(Precision)와 전체적인 구분 성능(PR-AUC 0.7422~~ 0.7548)면에서는 LightGBM이 상대적으로 더 우수한 것으로 평가되었습니다.

- **임계값 최적화** : Validation 데이터 기준 임계값(Threshold)을 탐색한 결과, F1-score를 극대화하는 구간은 0.50~0.55 수준으로 확인되었습니다.

2. 데이터 파이프라인 및 데이터셋 구성 (Data Pipeline & Dataset)

2.1. 데이터 다운로드, 인코딩 및 통합

1. **데이터 수집** : Google Drive에 저장된 압축 파일(train_data.zip, val_data.zip)을 gdown 라이브러리를 통해 수령 후 /content/train_unzipped, /content/val_unzipped 경로에 해제하였습니다.
2. **다중 인코딩 대응 함수 (read_csv_safely)** : 파일별 인코딩 상이 문제를 해결하기 위해 utf-8 $\rightarrow$ utf-8-sig $\rightarrow$ cp949 $\rightarrow$ euc-kr 순서로 자동 시도하는 안전한 로딩 파이프라인을 구축하였습니다.
3. **파일 병합 및 출처 기록** : Train 및 Validation 각각 16개 분기별 CSV 파일(2021년 1분기~2024년 4분기)을 탐색하여 병합하였으며, 데이터 추적성을 확보하기 위해 source_file 컬럼을 새로 추가하였습니다.

2.2. 데이터 세트 규모 및 분할 전략

구분,전체 통합 데이터,Training (70%),Validation (10%),Test (20%)
행 수 (Rows),"1,952,871","1,367,009","195,287","390,575"
열 수 (Columns),33,33,33,33
이상거래 비율,약 3.8%,"약 3.8% (50,405건)","약 3.8% (7,201건)","약 3.8% (14,402건)"

- train_test_split의 stratify=all_df"이상거래여부" 옵션 및 random_state=42를 지정하여 모든 데이터셋 내 target 클래스 분포의 균일성을 보장하였습니다.

3. 데이터 누수 방지 및 피처 엔지니어링

3.1. 데이터 누수 방지 5대 원칙 (Data Leakage Prevention Rules)

1. **결측치 대체 기준** : 연속형 변수의 중앙값은 전적으로 Train 데이터에서만 산출하여 Validation 및 Test 세트에 적용.
2. **카드별 평균 결제금액** : Train 데이터 내 산출 시 **현재 본인 거래 건을 제외** 한 평균 (sum - amt) / (count - 1)을 계산.
3. **미확인 카드의 대체값** : 거래 건수가 1건이거나 Test 세트에만 존재하는 신규 카드의 경우 Train 전체 승인금액의 중앙값(**9,000원**)으로 대체.

4. **스케일러 기틀** : RobustScaler 학습(fit)은 오직 Train 데이터로만 수행.
5. **클래스 불균형 기법** : SMOTENC 오버샘플링은 Train 데이터에만 한정 적용하고, Test 데이터는 원본 클래스 비율을 정밀히 유지.

3.2. 변수 제외 사유 (Excluded Features)

- **정답 누수 (Leakage) 위험 변수** : 이상거래유형, 이상거래설명 (사후에 판명되는 정답 정보이므로 모델 입력 시 실제 거래 시점과 불일치 발생).
- **단순 식별자** : 승인SEQ, 가맹점KEY (순서 의존성 유발 및 고유값이 과도하여 과적합 우려).
- **개인정보 및 편향 유발 변수** : 남녀구분코드, 연령 (특정 집단에 대한 편향 판정 및 공정성 문제 예방 차원에서 1차 기준 모델 제외).
- **기타 세부 코드형 변수** : 가맹점/거래 관련 다수의 코드 변수는 단순 외우기 방지를 위해 보류.

3.3. 최종 입력 변수 피처 구성 (총 13개)

원본 변수 (7개)

1. 통합승인금액 (amt): 승인 금액
2. 카드이용한도금액 (limit): 카드 한도 금액
3. 승인시간대 (hour): 거래 발생 시각
4. 국내해외여부 (is_overseas): 해외 거래 여부 (0: 국내, 1: 해외)
5. 가맹점여부_신규 (is_new_merchant): 신규 가맹점 여부
6. 인터넷판매여부 (is_online): 온라인/인터넷 결제 여부
7. 경과일수_최종이용일자 (days_since_last): 최근 카드 이용 후 경과일

이상거래 탐지용 파생 변수 (6개)

파생 변수명,산출 방식 및 정의,목적 및 탐지 메커니즘

amt_to_limit_ratio,통합승인금액 ÷ 카드이용한도금액 (한도 > 0 조건),카드 이용한도 대비 과도한 결제 시도 탐지

limit_is_zero,카드이용한도금액 == 0 여부 (1/0),한도 설정이 0인 특수 거래 및 비율 계산 불가 거래 구분

is_midnight,승인시간대 00시 ~ 05시 여부 (1/0),심야 시간대의 취약한 이상거래 패턴 반영

is_weekend,승인일자 기준 주말(토/일) 여부 (1/0),평일과 주말의 결제 행동 양식 차이 반영

amt_diff_from_user_avg,통합승인금액 - 카드별 평균 결제금액,고객의 평소 소비 수준 대비 이상 고액 결제 탐지

overseas_online_risk,국내해외여부 == 1 & 인터넷판매여부 == 1,해외 온라인 복합 고위험 거래 탐지

4. 데이터 전처리 및 불균형 해소 (Preprocessing & Imbalance Handling)

4.1. 결측치 및 이상치 처리

- **연속형 변수 (Numeric)** : amt, limit, hour, days_since_last, amt_to_limit_ratio, amt_diff_from_user_avg
- 무한대(inf, -inf) 값을 NaN으로 변환 후, Train 데이터에서 산출된 **연속형 피처별 중앙값** 으로 대체 완료 (처리 후 Train, Valid, Test 결측치 0건).
- **범주형 변수 (Categorical)** : is_overseas, is_new_merchant, is_online, limit_is_zero, is_midnight, is_weekend, overseas_online_risk
- 결측치를 **숫자 2 (UNKNOWN)**로 대체하여 모델이 기존의 0 (아니오), 1 (예)과 구분되는 독립적 범주로 인식하도록 설정.

4.2. RobustScaler 스케일링

승인금액 등 금융 데이터 특성상 존재하는 극단적 이상치의 영향을 완화하기 위해 평균/표준편차가 아닌 **중앙값(Median) 및 사분위수 범위(IQR)** 기반의 RobustScaler를 적용하였습니다.

4.3. SMOTENC를 활용한 클래스 불균형 완화

연속형 변수와 범주형 변수가 혼재된 데이터 특성을 반영하여 **SMOTENC (Synthetic Minority Over-sampling Technique for Nominal and Continuous)**를 적용하였습니다.

- **설정 매개변수** : sampling_strategy=0.2 (소수 클래스인 이상거래의 개수를 다수 클래스 정상거래의 20% 수준까지 오버샘플링), random_state=42

구분,SMOTENC 적용 전 (Train),SMOTENC 적용 후 (Train)

정상거래 (Class 0),"1,316,604건","1,316,604건"

이상거래 (Class 1),"50,405건 (약 3.8%)","263,320건 (정상거래의 20%)"

총 샘플 수,"1,367,009건","1,579,924건"

5. 모델별 성능 평가 및 비교 분석 (Model Performance & Analysis)

모든 모델은 동일한 평가 지표인 **Precision(정밀도), Recall(재현율), F1-score, PR-AUC(Precision-Recall Area Under Curve)**를 중심으로 검증되었습니다.

5.1. LightGBM 단일 모델 (SMOTENC 미적용 vs 적용 비교)

- **하이퍼파라미터 설정** : n_estimators=300, learning_rate=0.05, max_depth=6, num_leaves=31, random_state=42, n_jobs=-1
- **기본 임계값(Threshold)** : 0.5

데이터셋,모델 유형,이상거래 Precision,이상거래 Recall,이상거래 F1-score,PR-AUC,Accuracy

Validation,SMOTENC 미적용,0.8381 (0.8446),0.6500 (0.6429),0.7322 (0.7300),0.7569 (0.7694),0.9825

,SMOTENC 적용,0.8001 (0.8534),0.6705 (0.6629),0.7296 (0.7462),0.7485 (0.7818),0.9817

Test (최종),SMOTENC 미적용,0.8388 (0.8251),0.6339 (0.6366),0.7221 (0.7187),0.7503 (0.7635),0.9820

,SMOTENC 적용,0.8019 (0.8077),0.6572 (0.6511),0.7224 (0.7210),0.7426 (0.7650),0.9814

괄호 안의 수치는 요약 텍스트 절에 수록된 세부 실험 모듈별 측정치입니다.

- **비교 분석 요약** :
- SMOTENC를 적용할 경우, 이상거래를 놓치지 않고 잡아내는 **Recall 지표가 상승** (Test 기준 0.6366 $\rightarrow$ 0.6511 / 코드 실행 0.6339 $\rightarrow$ 0.6572)하였습니다.
- 이상거래를 최대한 적발하는 것이 핵심 목적인 FDS 시스템의 특성상, 미탐을 줄여주는 **LightGBM + SMOTENC 조합이 실무 적용에 더 적합** 한 모델로 평가됩니다.

5.2. LightGBM + SMOTENC 임계값(Threshold) 최적화 분석

Validation 데이터셋을 대상으로 임계값을 0.20부터 0.70까지 0.05 단위로 정밀 탐색한 결과입니다.

Threshold,Precision,Recall,F1-score,Accuracy,순위 (F1 기준)

0.55,0.8202,0.6600,0.7315,0.9821,1위

0.60,0.8312,0.6505,0.7298,0.9822,2위

0.50,0.8001,0.6705,0.7296,0.9817,3위

0.65,0.8400,0.6438,0.7289,0.9823,4위

0.45,0.7735,0.6821,0.7250,0.9809,5위

0.40,0.7371,0.6987,0.7174,0.9797,7위

0.30,0.6013,0.7573,0.6703,0.9725,9위

0.20,0.4181,0.8521,0.5610,0.9508,11위

- **임계값 정책 결정** :
- Validation F1-score 관점에서는 **0.55** 에서 가장 우수한 F1-score(0.7315)를 보였습니다.
- F1-score의 균형과 안정성을 종합 검토할 때 **0.50 ~ 0.55** 구간이 최적의 작동 지점이며, 만약 현업 운영상 오탐 증가를 감수하더라도 미탐 완화(Recall 증대)가 최우선 과제라면 임계값을 0.35~0.40 수준으로 낮추어 운용하는 전략도 가능합니다.

5.3. Random Forest 및 XGBoost 모델 비교 평가

SMOTENC가 적용된 동일 조건하에 타 머신러닝 알고리즘과 비교 실험을 진행하였습니다.

Random Forest (n_estimators=300, max_depth=12, min_samples_leaf=2)

- **Validation (Threshold 0.55/0.50)** : Precision 0.7732 / 0.7634, Recall 0.6878 / 0.6987, F1-score 0.7280 / 0.7296, PR-AUC 0.7453 / 0.7490
- **Test 최종 (Threshold 0.55/0.50)** : Precision 0.7804 / 0.7261, Recall 0.6742 / 0.6945, F1-score 0.7234 / 0.7100, PR-AUC 0.7422 / 0.7548

XGBoost (n_estimators=300, learning_rate=0.05, max_depth=6, subsample=0.8, colsample_bytree=0.8, tree_method="hist")

- 히스토그램 기반의 XGBoost 알고리즘 학습 파이프라인 구축 완료.

머신러닝 모델 종합 비교 요약

평가 지표 (Test 기준),LightGBM + SMOTENC,Random Forest + SMOTENC

이상거래 Recall,0.6511 ~ 0.6572,0.6742 ~ 0.6945 (높음)

이상거래 Precision,0.8019 ~ 0.8077 (높음),0.7261 ~ 0.7804

이상거래 F1-score,0.7210 ~ 0.7224 (우수),0.7100 ~ 0.7234

PR-AUC (종합 구분력),0.7426 ~ 0.7650 (우수),0.7422 ~ 0.7548

6. 결론 및 향후 과제 (Conclusions & Recommendations)

- **최적 모델 선정** : **LightGBM + SMOTENC** 모델이 Precision과 Recall 간의 뛰어난 균형감과 가장 높은 PR-AUC(0.7650)를 기록하여 카드 거래 이상탐지를 위한 최종 1차 기준(Baseline) 모델로 채택되었습니다.
- **데이터 누수 방지 효과 검증** : 학습-평가 데이터 분리 및 전처리 과정에서의 누수 차단 원칙을 엄격하게 준수함으로써 Validation 성능과 Test 성능 간 격차가 매우 적고 안정적인 일반화 성능을 입증하였습니다.
- **후속 개선 과제** :
- **보류 변수 단계적 재투입** : 1차 모델에서 과적합 방지를 위해 제외했던 세부 업종 코드, 거래 경로 코드 등의 변수를 하나씩 추가 학습하여 F1-score 및 PR-AUC의 추가 상승 여부를 검증할 예정입니다.
- **운영 임계값 설정** : FDS 시스템 운영 목적(미탐 방지 vs 오탐 차단)에 맞추어 Validation 데이터 기반의 분류 임계값 조정을 가동 환경에 맞게 미세 조정(Tuning)하는 작업을 권장합니다.