삼성 AXI 6개월 과정 최종 프로젝트 | 엔터프라이즈 AI 감사 보고서

Heartbeats: Prompt Agent 맥락 연속성 & 임상급 보안 AI 정서 케어 시스템

삼성 AXI 최종 발표 정밀 검토 · LoRA 요약 진화·위기 안전망·3-DB AES-256-GCM 감사

작성 팀 / 작성자	검토 대상 문서	검토 일시	검토 기관 / 담당
Team Heartbeats (이현표·이새봄·송지현·현다은)	1개 (PDF 최종 발표서, 23장)	2026년 06월 19일	DMDG 기술심사위원회 (Sherlock & Craig)

EXCELLENT (A+)

94

TOTAL SCORE / 100

1. Prompt Agent 맥락 연속성 & LoRA 진화
95
2. 임상 척도(PHQ-9·GAD-7·ISI) & 맞춤 페르소나
94
3. 실시간 위기 감지 & 2단계 Safety 게이트
96
4. 3-DB 물리격리 · AES-256-GCM 보안 설계
97
5. 성실한 한계 인식 & 라이브 데모 완결성
89

1. 총평 및 핵심 심사 의견 (Executive Summary)

임상안전·보안 탁월 A+

🏆 **6단계 요약 모델 진화 + Prompt Agent 맥락 압축 + 3-DB 물리격리·INSERT-only 감사로그까지 갖춘 완성형 멘탈헬스 AI**

기존 감정챗봇의 4대 치명적 결함(매 세션 맥락 단절, 획일적 말투, 위기발화 오탐/미탐, 데이터 불신)을 정면 돌파했습니다. 특히 요약(LoRA YAML 구조화)과 위험분류(Risk Classifier) 책임을 분리한 결정, 1~10 페르소나 슬라이더, Function Calling + 종료 후 재검증 2중 위기 감지(109/1577-0199 즉시 노출), 사용자 본문 암호화(AES-256-GCM)와 3-DB 격리는 실제 디지털 치료제/EAP B2B 도입 수준입니다.

⚠️ **위기 감지 '오탐/미탐' Confusion Matrix 정량 평가 & 암호화 키(KMS/Envelope Key) 순환 정책 구체화 필요**

슬라이드에 Function Calling 기반 1차 위기판단('부정·해소 표현 제외')과 2차 risk_level 재검증 구조를 훌륭히 설계했으나, 가벼운 관용적 한탄('힘들어 죽겠다') vs 실제 자해 위험 구분 정확도(Recall/F1) 실측 수치와, AES-256-GCM 암호화 키 분실 시 복구 불가 또는 내부자 KMS 접근통제 시나리오 보완이 필요합니다.

검토 대상 파일명	파일 형식	검증 상태	핵심 검증 결과 요약
Heartbeats_이현표 이새봄 송지현 현다은.pdf	PDF (발표서 23p)	최우수 (A+)	6차 모델 진화 서사·PHQ-9/GAD-7/ISI 연동·3-DB 격리·정직한 로드맵 탁월

2. Prompt Agent 메타-아키텍처 · Safety 분류기 및 3-DB 보안 정밀 감사

정밀 감사

📌 [AI 아키텍처 & 안전망 감사] 책임 분리(Decoupling)와 토큰 효율성

설계 모범 사례

서브모듈	핵심 메커니즘	해결된 난제	검증 보강 항목
Prompt Agent	과거 3회 YAML 요약 + PHQ-9/GAD-7/ISI + 슬라이더 → JSON system_prompt	전체 history 재전송 토큰 폭증 제거	슬라이더 극단값(전문성10·공감1) 톤 QA
LoRA 요약 진화	1차 저장→3차 YAML 5키→4차 LoRA→5차 Risk 분리→6차 사실중심 메모리	감정 과잉 대신 사건·관계 보존	LoRA YAML 파싱 실패 시 JSON Repair율
Crisis Safety	Function Calling(현재발화) + 종료 후 별도 분류 LLM + 109/1577 연결	위기 미탐 및 과잉반응 방지	위기 키워드 Red-Teaming 셋 Recall ≥ 99%
3-DB + 암호화	인증/상담본문/감사DB 물리격리 + INSERT-only + AES-256-GCM	데이터 변조·유출 원천 차단	데이터 주권(회원탈퇴 시 암호화폐기 Crypto-shredding)

📌 [의료/임상 규제 주의] '의료행위 오인 방지' 면책 UI 및 전문가 에스컬레이션

컴플라이언스

- **비의료 정서케어 경계선 명시:** PHQ-9/GAD-7/ISI 국제 표준 척도를 자동 채점·반영하므로 온보딩 및 결과 화면에 '본 서비스는 의학적 진단·치료를 대체하지 않으며 위험 시 전문기관(109)과 연계한다'는 면책 고지를 상시 노출하세요.
- **Prompt Agent 실패 폴백:** 메타-LLM 지연/오류로 세션별 system_prompt 생성이 타임아웃되면 즉시 안전 기본 프롬프트(Fallback Empathy Template)로 기동되도록 서킷브레이커를 두세요.

> 💡 **기술심사위원회 종합 소견**
>
> 기획·데이터 파이프라인·모델 평가·실시간 서빙 간 정합성을 확보하고 3장의 교정 솔루션을 즉시 적용하면 실무 수준의 완성도와 데모 설득력을 크게 높일 수 있습니다.

3. 개선 솔루션 및 기술 보완 가이드 (Actionable Fixes)

교정 솔루션

📌 영역별 핵심 보완 항목

Action Items

해당 절 / 영역	발견된 문제점 및 보완점	수정 제안 (Action Item)
위기 평가	위기 감지(critical/high/medium/low)의 Precision/Recall 실측 벤치마크 표 부재	임상/상담 Red-Teaming 문장 100건('해소표현' vs '실제 위기') 기준 Confusion Matrix 공개
지연시간	세션 시작 시 Prompt Agent(메타-LLM) 호출로 첫 응답 TTFT 지연 가능	직전 세션 종료 즉시 차기 세션용 `system_prompt`를 비동기 Pre-compute 캐싱
암호화 운영	AES-256-GCM 본문 암호화 키 관리/사용자 삭제권(Crypto-Shredding) 미명시	사용자별 DEK를 KMS KEK로 감싸 저장하고 탈퇴 시 DEK 파기해 즉시 완전 불능화

🔧 [Fix 1] 차기 세션 지연 Zero화를 위한 비동기 Prompt Agent Pre-warming
@background_task def on_session_close(user_id: str, session_id: str): summary_yaml = lora_summarizer.run(session_id) next_sys_prompt = prompt_agent.build(user_id, last_3_summaries, latest_phq9, persona) encrypted_store.save_precomputed_prompt(user_id, encrypt_aes_gcm(next_sys_prompt))
🔧 [Fix 2] 위기 감지 Function Calling + 규칙 기반 Hard Keyword 2중 안전망
if regex_immediate_selfharm_guard(user_utterance) or llm_risk_tool(utterance) in ('critical', 'high'): return CrisisResponse(hotlines=['109', '1577-0199'], tone='warm_urgent_handoff')

4. 실전 고도화 전략 & 최종 검증 체크리스트 (Success Strategy)

검증 가이드

💉 1. '요약 모델 1→6차 진화 사유'를 핵심 엔지니어링 스토리로

기술 면접 최적

왜 단순 프롬프트가 아니라 YAML 고정, LoRA 튜닝, Risk 분리, 사실 메모리로 바꿨는지 설명한 10쪽은 최상급 평가 포인트입니다.

🎛️ 2. 동일 질문('요즘 너무 지쳐요')에 대한 페르소나 극과 극 대비

직관적 데모

공감1·전문성10 vs 공감10·전문성1 응답 차이를 라이브 데모에서 바로 보여주면 청중 이해도가 100% 됩니다.

🛡️ 3. INSERT-only 감사 DB & 3-DB 격리를 B2B/대학상담센터 세일즈 강점으로

신뢰 자산

대학/기업 EAP(근로자지원프로그램) 도입 시 개인정보·상담 비밀보장이 최우선 요건임을 강조하세요.

🩺 4. 전문 상담사 연계용 '1장 요약 브리프(환자 동의 시)' 로드맵

비전 확장

기존 상담에 들어가기 전 AI가 최근 3회 요약과 PHQ-9 변화 추이를 한 장으로 정리해 넘기는 기능까지 제안하세요.

📋 최종 완결성 점검 체크리스트 (Sherlock Final Checklist)

구분	점검 항목	점검 내용 및 기준	상태
안전망	**Red-Teaming 100문항 위기감지 F1 측정**	'힘들어 죽겠다' 관용어 오탐 억제 + 진짜 위기 Recall ≥ 99%	검증 보강
UX/성능	**세션 종료 시 차기 System Prompt 선계산**	신규 상담 진입 시 첫 응답 2초 이내 확보	최적화 권고
보안	**3-DB 격리 · AES-256-GCM · 비의료 고지**	개인정보보호법 민감정보 암호화 및 면책 고지 확인	구현 완료

DMDG (당목담글) 교육사업본부 & AI 연구소 기술인증위원회

본 기술 검토서는 제출된 기획서·발표자료·산출물의 데이터 정합성, 모델링 타당성, 아키텍처 완성도 및 발표 설득력을 종합 평가하여 발행되었습니다.
Team Heartbeats (이현표·이새봄·송지현·현다은) 의 지속적인 성장과 성공적인 프로젝트 완수를 응원합니다.